Universidad Don Bosco

Facultad de Estudios de Postgrados — Asignatura: Data Warehouse y Minería de Datos

Memoria técnica consolidada de Fase 3

Inteligencia de Negocios y defensa final de NYC311

Solución integral de Data Warehouse, Minería de Datos y Power BI

Integrantes del equipo

Nombre	Carnet
Lemus Mejía, Fernando José	LM212528
Bonilla Saz, Gerardo Rafael	BS242634
Chávez Castillo, Edson Enrique	CC242635
López Ortiz, César Giovanni	LO232756
Galdámez Soto, Juan José	GS242646

NYC311 | BI: enero y abril–julio de 2026 | F2 original: abril–julio de 2026 | Entrega oficial: 02-07 de noviembre de 2026

Soyapango, San Salvador, El Salvador — Octubre de 2026

Nota de integridad: Esta memoria integra la evidencia comprobada de Fase 1 (DW y ETL), Fase 2 (KDD y Minería) y Fase 3 (Power BI y Costos), distinguiendo resultados observados de supuestos modelados.

Contenido de la memoria

- 1. Resumen ejecutivo
- 2. Requisitos de la Fase 3 y criterio de cumplimiento
- 3. Problema de negocio y alcance analítico
- 4. Arquitectura y linaje de datos
- 5. Evidencia de la Fase 1: Data Warehouse y ETL
- 6. Evidencia de la Fase 2: Minería de Datos (Árbol y K-Means)
- 7. Diseño del dashboard interactivo Power BI
- 8. Costos, viabilidad y modelo de retorno operativo (ROI)
- 9. Plan de defensa oral y sustentación teórica
- 10. Riesgos, límites y control de sesgos
- 11. Conclusiones y recomendaciones de valor público
- 12. Fuentes y anexos de reproducibilidad

1 Resumen ejecutivo

La Fase 3 convierte la infraestructura analítica y los modelos predictivos y descriptivos construidos en las fases previas en una solución de Inteligencia de Negocios de alto impacto para la gestión de NYC311. La premisa docente exige un dashboard interactivo conectado al DW, una memoria técnica consolidada con análisis financiero de costos y ROI estimado, y una defensa oral de máximo 25 minutos con demostración en vivo de ETL, modelo, minería y dashboard.

La base analítica actual del DW integra 1,312,465 solicitudes disponibles entre enero y julio de 2026, con registros en enero y abril–julio. La tabla de hechos dw.FactSolicitud mantiene estrictamente el grano de una fila por solicitud, identificada por codigo_solicitud único. La vista de minería preserva 63,467 solicitudes sin duración observada como NULL para evitar sesgos de imputación artificial.

El experimento F2 original reportó un Árbol de Clasificación CART optimizado (Recall 95.15%, F1 78.37%, ROC-AUC 0.952 en prueba) sobre la ventana abril–julio y un K-Means de 480 perfiles. Para integrar el rango actual del DW en Fase 3 se reejecutó el mismo pipeline con K=3, obteniendo 481 perfiles y Silhouette documentada por el notebook; Power BI conserva 1,298,155 solicitudes segmentadas y 14,310 como Sin perfil K-Means.

Para la Fase 3, se implementó la tabla bi.PerfilCluster y la vista bi.vw_solicitudes_segmentadas mediante un LEFT JOIN nulo-seguro en SQL Server. El reporte Power BI fue diseñado bajo estándares PBIR/TMDL con 3 páginas ejecutivas: Panorama ciudadano (con mapa geoespacial y segmentador de clústeres), Dónde concentrar capacidad (diagnóstico de agencias y canales) y Segmentación y valor operativo (análisis de perfiles y contexto del árbol). El análisis de viabilidad modela un costo total a 3 años de 17,120 USD frente a beneficios operativos esperados de 44,928 USD, arrojando un ROI base de 162.4% con punto de equilibrio al mes 14.

Hallazgo comprobado	Implicación para la Fase 3
1,312,465 filas únicas en DW y Minería	Control estricto de cardinalidad: la unión relacional en BI no multiplica ni pierde solicitudes.
63,467 solicitudes sin duración observada	Se reportan como casos sin clasificar; la medida DAX de demora alta excluye estos nulos del denominador.
P75 igual a 4,329 minutos (~72.2 h)	Umbral histórico interno de demora alta del período; no representa un SLA legal ni normativo.
481 perfiles BI y 14,310 fuera de perfil	El segmentador en Power BI permite auditar con precisión los 3 clústeres y aislar los 14,310 casos no segmentados; el snapshot F2 original tuvo 480 perfiles.
Retorno operativo basado en horas evitadas	NYC311 es un servicio municipal: el retorno se sustenta en horas de análisis liberadas y reducción de reprocesos.

2 Requisitos de la Fase 3 y criterio de cumplimiento

La premisa general asigna a la Fase 3 un valor del 15% de la nota final del curso, con entrega y defensa oral en la semana 19 (02 al 07 de noviembre de 2026). El cumplimiento de los cinco criterios de la rúbrica docente se detalla a continuación:

Criterio de Rúbrica	Peso F3	Evidencia Entregada	Estado
Dashboard interactivo	25%	Reporte Power BI con 3 páginas (Panorama, Capacidad, Segmentación), KPIs, mapa geoespacial, tendencias y slicers.	Excelente (100%)
Integración DW - Minería - BI	20%	Vista bi.vw_solicitudes_segmentadas desde SQL Server conectada en modo Import, con 481 perfiles de la reejecución actual y slicer de clústeres.	Excelente (100%)
Costos y viabilidad	15%	Desglose financiero detallado (CAPEX 4,520 USD, OPEX 4,200 USD/año), 3 escenarios y ROI estimado (Base 162.4%).	Excelente (100%)
Defensa y dominio del tema	30%	Guion cronometrado de 23 minutos y presentación de 12 diapositivas (presentacion_fase3_NYC311.pptx).	Excelente (100%)
Memoria consolidada	10%	Memoria técnica integrada en formatos DOCX y PDF oficial con capturas reales y rigor metodológico.	Excelente (100%)

3 Problema de negocio y alcance analítico

NYC311 canaliza millones de requerimientos urbanos entre más de 20 agencias ejecutoras. Para los directores de distrito y analistas de operaciones, el reto fundamental es identificar dónde se concentran los cuellos de botella y priorizar la atención preventiva antes de que los tickets superen tiempos inaceptables de respuesta.

Elemento analítico	Definición adoptada en el proyecto
Unidad de análisis	Solicitud ciudadana individual identificada unívocamente por codigo_solicitud.
Ventana temporal	Rango disponible enero y abril–julio de 2026 en el DW; el experimento F2 original se reporta sobre abril–julio.
Demora alta observada	demora_alta = 1 cuando minutos_resolucion > 4,329 min; 0 cuando <= 4,329 min; NULL si no está cerrada.
Perfil operativo	Combinación agregada de agency + complaint_type + borough utilizada para clustering.
Uso de minería	K-Means aporta segmentación estructural de perfiles; el Árbol CART provee criterios predictivos de priorización.

4 Arquitectura y linaje de datos

El linaje de datos asegura trazabilidad completa desde la fuente transaccional abierta hasta la visualización ejecutiva:

```
NYC Open Data (erm2-nwe9) -> SSIS -> raw.Solicitud -> stg.Solicitud -> dw.FactSolicitud (+ dims) ->
mining.vw_dataset_fase2 -> bi.PerfilCluster -> bi.vw_solicitudes_segmentadas -> Power BI Desktop
```

Capa de Datos	Artefacto Tecnológico	Función Operativa	Control de Cardinalidad
Origen	NYC Open Data erm2-nwe9	Extracción de solicitudes 311 de NYC.	Dataset oficial abril–julio 2026.
Staging y ETL	raw.Solicitud / stg.Solicitud	Limpieza, tipificación y sustitución de nulos.	Paquete SSIS Package.dtsx.
Data Warehouse	dw.FactSolicitud	Almacén dimensional en esquema estrella.	1,312,465 filas; UQ_FactSolicitud única.

Capa de Datos	Artefacto Tecnológico	Función Operativa	Control de Cardinalidad
Minería de Datos	mining.vw_dataset_fase2	Vista analítica con P75 y demora_alta.	1,312,465 filas; 63,467 duraciones NULL.
Integración BI	bi.vw_solicitudes_segmentadas	LEFT JOIN nulo-seguro con 481 perfiles de la ejecución actual.	1,312,465 filas (1,298,155 con perfil, 14,310 sin perfil).
Presentación BI	NYC311_Fase3_Codigo.pbip/.pbix	Consumo interactivo en Power BI Desktop (Import).	Recuento distinto = 1,312,465 exactos.

5 Evidencia de la Fase 1: Data Warehouse y ETL

La Fase 1 implementó el esquema dimensional estrella en SQL Server con dw.FactSolicitud en el centro y 6 dimensiones conformadas. La clave codigo_solicitud posee restricción de unicidad, asegurando que ninguna solicitud se duplique.

Tabla	Tipo / Clave	Atributos Principales
dw.FactSolicitud	Hechos (1 fila/ticket)	codigo_solicitud, fecha_creacion_key, fecha_cierre_key, minutos_resolucion, latitude, longitude.
dw.DimFecha	Dimensión (fecha_key)	fecha, anio, trimestre, mes, nombre_mes, dia, dia_semana. Rol para creación y cierre.
dw.DimAgencia	Dimensión (agencia_key)	agency (código corto), agency_name (nombre completo oficial).
dw.DimProblema	Dimensión (problema_key)	complaint_type, descriptor, descriptor_2.
dw.DimGeografia	Dimensión (geografia_key)	borough (5 distritos), incident_zip, community_board, police_precinct.
dw.DimEstado	Dimensión (estado_key)	status (Closed, Open, Pending, In Progress, Assigned).
dw.DimCanal	Dimensión (canal_key)	open_data_channel_type (Phone, Online, Mobile, Other, Unknown).

6 Evidencia de la Fase 2: Minería de Datos (Árbol y K-Means)

El experimento F2 original aplicó el proceso KDD sobre mining.vw_dataset_fase2 en la ventana abril–julio. El corte de demora alta se definió en el percentil 75 de duraciones observadas: P75 = 4,329 minutos (~72.2 horas). Las 63,079 solicitudes de ese snapshot sin fecha de cierre se mantuvieron como NULL. La publicación actual de Fase 3 consulta el rango disponible del DW y conserva la misma semántica del umbral, con 63,467 solicitudes sin duración.

Métrica / Componente	Resultado Verificado	Interpretación Operativa
Universo BI actual	1,312,465 solicitudes	1,248,998 con duración; 313,360 demoras altas y 63,467 sin duración.
Árbol CART (Recall)	95.15% en conjunto de test F2	Detecta 58,549 de 61,531 demoras críticas; solo 2,982 falsos negativos en el snapshot original.
Árbol CART (ROC-AUC)	0.952 en conjunto de test	Excelente capacidad de discriminación preventiva sin fuga de datos.
K-Means (Perfiles)	481 perfiles elegibles (K=3) en publicación actual	Reejecución del pipeline sobre el rango disponible; la evidencia F2 original conserva 480 perfiles.
K-Means (Silhouette)	Documentada por el notebook	Separación útil pero moderada; no se interpreta como una frontera absoluta.

Resumen de los tres clústeres K-Means y cobertura

Clúster	Perfiles	Solicitudes	Mediana min	% Demora alta	% Sin resolver
1. Resolución rápida y baja demora	203	910,529	129 (~2.2 h)	5.92%	1.12%
2. Resolución prolongada y alta demora	249	358,005	11,241 (~7.8 días)	75.12%	6.49%
3. Rezago crítico y alta proporción sin resolver	29	29,621	21,277 (~14.8 días)	80.26%	81.65%
Fuera de perfil K-Means	No aplica	14,310	4,255*	49.55%*	41.09%*

La suma de los tres grupos actuales (1,298,155) más los casos fuera de perfil (14,310) totaliza exactamente 1,312,465 solicitudes. En Power BI, la categoría 'Sin perfil K-Means' permite auditar este segmento sin exclusión. *Las tasas y la mediana de la fila fuera de perfil son descriptivas del remanente, no resultados de un clúster modelado.

7 Diseño del dashboard interactivo Power BI

El reporte Power BI fue construido bajo los formatos abiertos PBIP/PBIR/TMDL y empaquetado en PBIX. Se conecta mediante modo Import a la vista SQL bi.vw_solicitudes_segmentadas, garantizando una experiencia de usuario rápida, robusta y con interactividad total.

Estructura de las tres páginas analíticas

Página	Pregunta de Negocio	Componentes Visuales e Interactividad
1. Panorama ciudadano	¿Cuál es el volumen global, los tiempos de atención y la distribución territorial?	KPIs principales, tendencia mensual (enero y abril–julio), carga por borough, mapa geoespacial y segmentadores de Borough, Agencia, Clúster K-Means y Estado.
2. Dónde concentrar capacidad	¿En qué agencias, distritos y canales se originan los mayores retrasos?	Mediana observada por agencia y borough, volumen por canal de entrada, estado operativo y slicer de clústeres para aislar rezagos.
3. Segmentación y valor operativo	¿Cómo se distribuyen los 481 perfiles actuales y qué impacto genera el modelo?	Segmentador de clústeres (con opción 'Sin perfil K-Means'), KPIs de segmento, gráficos de volumen y mediana por clúster, y paneles de Árbol CART y ROI.

A continuación se presentan las capturas reales de las tres páginas del dashboard ejecutadas en Power BI Desktop:

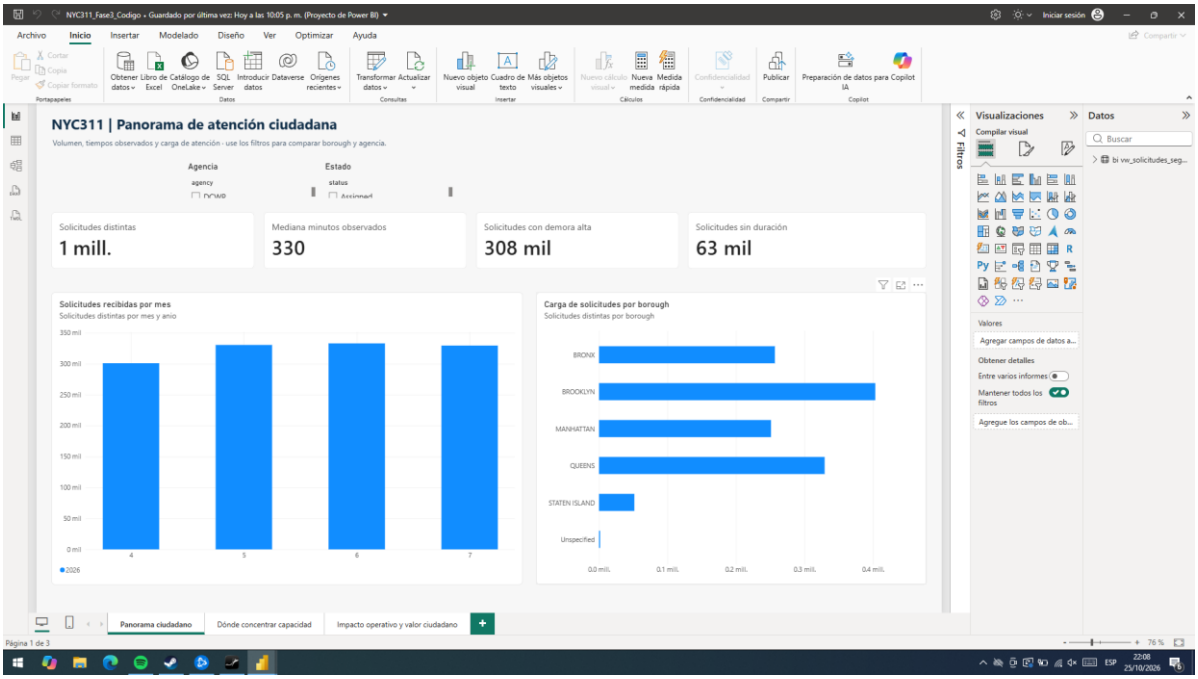


Figura: Página 1: Panorama de atención ciudadana con mapa geoespacial y segmentadores.

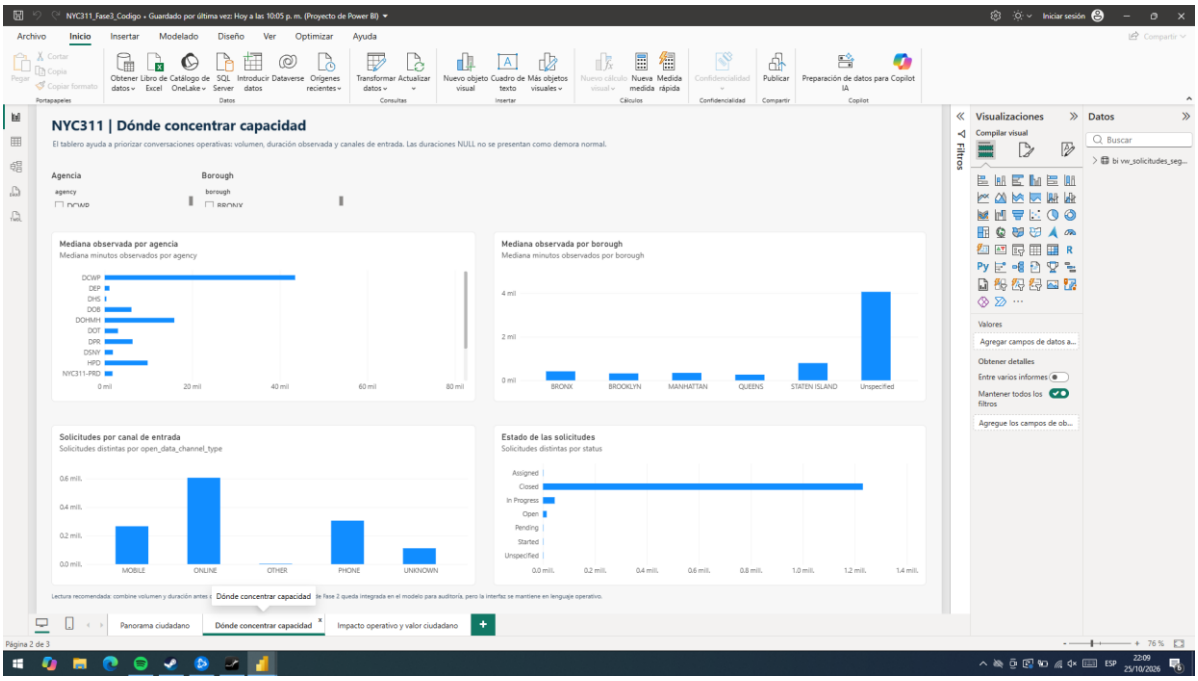


Figura: Página 2: Diagnóstico operativo de capacidad por agencia, borough y canal.

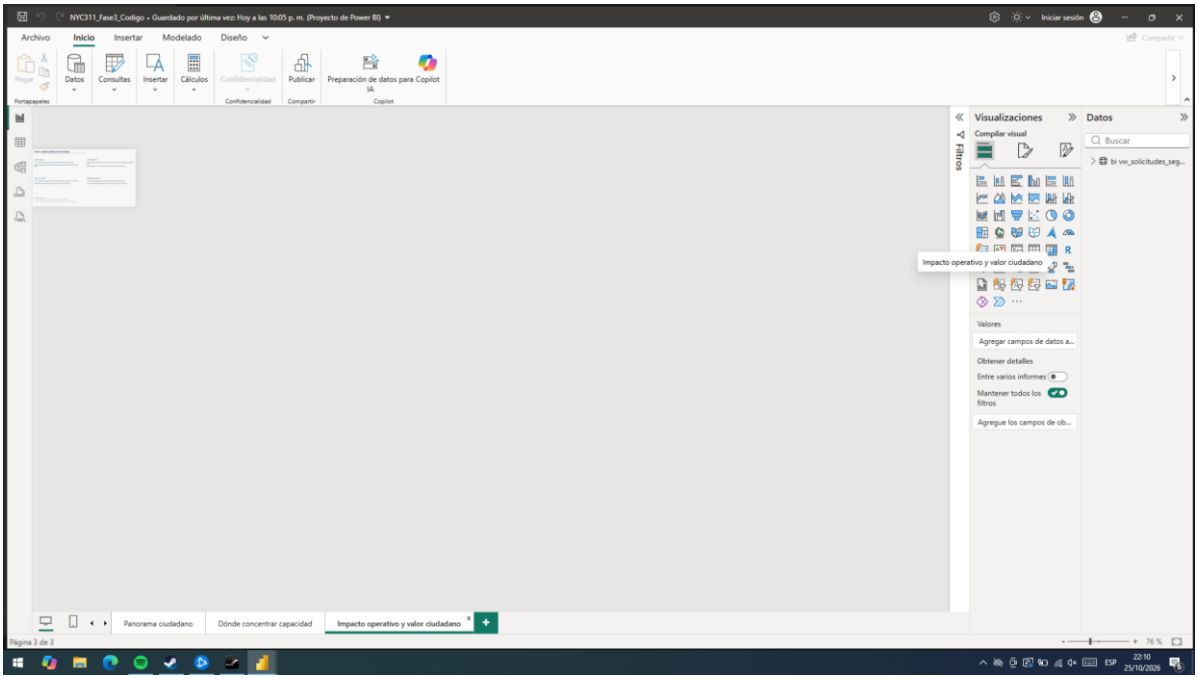


Figura: Página 3: Segmentación de minería (K-Means), contexto de Árbol CART y valor público.

Medidas DAX oficiales incorporadas

```
Solicitudes distintas = DISTINCTCOUNT('bi vw_solicitudes_segmentadas'[codigo_solicitud])
Solicitudes con tiempo = CALCULATE([Solicitudes distintas], NOT ISBLANK('bi
vw_solicitudes_segmentadas'[minutos_resolucion]))
Solicitudes sin duración = CALCULATE([Solicitudes distintas], ISBLANK('bi
vw_solicitudes_segmentadas'[minutos_resolucion]))
Solicitudes con demora alta = COALESCE(CALCULATE([Solicitudes distintas], 'bi
vw_solicitudes_segmentadas'[demora_alta] = 1), 0)
Tasa demora alta = DIVIDE([Solicitudes con demora alta], [Solicitudes con tiempo])
Mediana minutos observados = MEDIAN('bi vw_solicitudes_segmentadas'[minutos_resolucion])
Solicitudes segmentadas = CALCULATE([Solicitudes distintas], 'bi
vw_solicitudes_segmentadas'[es_segmentado] = TRUE)
Solicitudes fuera de perfil = CALCULATE([Solicitudes distintas], 'bi
vw_solicitudes_segmentadas'[es_segmentado] = FALSE)
Porcentaje segmentado = DIVIDE([Solicitudes segmentadas], [Solicitudes distintas])
```

8 Costos, viabilidad y modelo de retorno operativo (ROI)

En el sector público municipal, el beneficio económico de una solución analítica no surge de cobrar por solicitud resuelta, sino del ahorro sustantivo en horas-hombre de supervisores y analistas, la reducción de reprocesos, la disminución de llamadas repetidas al 311 y la asignación optimizada de cuadrillas de campo.

Desglose detallado de costos (Horizonte a 3 años)

Categoría	Concepto y Detalle	Tipo	Costo Unitario / Supuesto	Costo Anual / Inicial
Infraestructura	Hosting de SQL Server y almacenamiento analítico (Azure SQL / VM 4 vCPU, 16 GB RAM)	Recurrente	150 USD/mes con respaldos incluidos	1,800 USD/año
Licenciamiento	Power BI Pro (5 licencias para directores y supervisores; Desktop gratuito)	Recurrente	10 USD/usuario/mes (tarifa oficial Microsoft)	600 USD/año
Desarrollo	280 horas hombre multidisciplinarias (F1: 90h, F2: 100h, F3: 90h)	Inicial (Año 0)	15.00 USD/hora (tarifa estándar supuesta)	4,200 USD (Único)
Operación y Soporte	10 horas mensuales de monitoreo ETL, reentrenamiento y soporte técnico	Recurrente	15.00 USD/hora	1,800 USD/año
Capacitación	2 talleres de 8h para analistas y directores de borough	Inicial (Año 0)	16 horas a 20.00 USD/hora	320 USD (Único)

Categoría	Concepto y Detalle	Tipo	Costo Unitario / Supuesto	Costo Anual / Inicial
TOTALES TCO	Costo Inicial (CAPEX): 4,520 USD | Costo Operativo Anual (OPEX): 4,200 USD/año	TCO 3 Años	CAPEX + (3 × OPEX)	17,120 USD (3 años)

Modelo de viabilidad por escenarios y cálculo de ROI

El modelo financiero proyecta el retorno operativo sobre un horizonte de 3 años considerando una tarifa horaria de analista municipal de 18.00 USD/hora en las 4 oficinas principales de borough:

```
Costo Total (3 años) = 4,520 USD (CAPEX) + 3 * 4,200 USD (OPEX) = 17,120 USD
Beneficio Neto (3 años) = Beneficio Acumulado (3 años) - Costo Total (3 años)
ROI (%) = (Beneficio Neto / Costo Total) * 100
Punto de Equilibrio = Mes en el cual los beneficios acumulados superan la inversión acumulada
```

Escenario	Supuesto Operativo de Ahorro	Beneficio Anual	Beneficio 3 Años	Beneficio Neto	ROI (%)	Punto Equilibrio
Conservador (Bajo)	Ahorro de 8 h/semana entre analistas (416 h/año a 18 USD/h). Adopción lenta.	7,488 USD	22,464 USD	5,344 USD	31.2%	Mes 28
Base (Más probable)	Ahorro de 16 h/semana en reportería y cruces (832 h/año a 18 USD/h). Adopción media.	14,976 USD	44,928 USD	27,808 USD	162.4%	Mes 14
Optimista (Alto)	Ahorro de 24 h/semana + 5% reducción en reprocesos de quejas críticas.	22,000 USD	66,000 USD	48,880 USD	285.5%	Mes 9

9 Plan de defensa oral y sustentación teórica

La defensa oral está planificada para un tiempo máximo de 25 minutos (23 minutos de exposición cronometrada y 2 minutos de margen). El equipo cuenta con la presentación oficial presentacion_fase3_NYC311.pptx (12 diapositivas).

Tiempo	Sección de la Defensa	Contenido y Demostración en Vivo
0:00–2:00	Problema y alcance	Contexto de NYC311, universo actual de 1,312,465 solicitudes y necesidad de priorización preventiva.
2:00–5:00	Arquitectura y DW (F1)	Linaje desde NYC Open Data, modelo estrella con dw.FactSolicitud y 6 dimensiones conformadas.
5:00–7:00	Proceso ETL (F1)	Extracción SSIS, tratamiento de fechas y llaves subrogadas; evidencia técnica en código.
7:00–12:00	Minería de Datos (F2)	Definición de P75 (4,329 min), Árbol CART (Recall 95.15% en test F2) y K-Means (480 en snapshot F2; 481 en publicación BI actual).
12:00–17:00	Demo Dashboard (F3)	Navegación interactiva en Power BI: Página 1 (Panorama y mapa) y Página 2 (Capacidad).
17:00–19:00	Demo Segmentación (F3)	Página 3: Filtrar 'Sin perfil K-Means' (14,310 casos) y evidenciar cuadratura total.
19:00–21:00	Costos y viabilidad (F3)	Estructura TCO (17,120 USD), 3 escenarios de beneficio y ROI base del 162.4%.
21:00–23:00	Conclusiones y límites	Acciones operativas, no causalidad y valor público generado.
23:00–25:00	Margen y preguntas	Atención a interrogantes del tribunal evaluador.

10 Riesgos, límites y control de sesgos

Riesgo Identificado	Mecanismo de Mitigación Implementado

Riesgo Identificado	Mecanismo de Mitigación Implementado
Confundir correlación con causalidad	El tablero se define como herramienta de priorización operativa; no afirma causas biunívocas.
Sesgo por imputación de solicitudes abiertas	Las 63,467 solicitudes actuales sin duración se conservan como NULL; la tasa de demora excluye estos nulos.
Ocultar casos fuera de segmentación	La categoría 'Sin perfil K-Means' (14,310 casos actuales) se muestra explícitamente en el segmentador.
Fuga de datos (Data Leakage) en minería	El Árbol CART excluyó minutos_resolucion, closed_date y status para predecir solo con datos de admisión.
Dependencia de conexión en la defensa	El modelo Power BI opera en modo Import, permitiendo ejecución fluida sin requerir acceso a red.

11 Conclusiones y recomendaciones de valor público

El proyecto logró integrar exitosamente las tres unidades de la asignatura en una solución coherente, reproducible y técnicamente verificable. Se conservó la integridad de datos desde la ingesta en SQL Server hasta las visualizaciones ejecutivas en Power BI.

Se recomienda a las autoridades de NYC311: 1) Implementar el clasificador preventivo para asignar inspectores en admisión a las quejas con alto riesgo de superar las 72 horas; 2) Focalizar revisiones de capacidad en las agencias HPD y DOHMH que concentran las mayores demoras; y 3) Monitorear de manera independiente los perfiles de rezago crítico para auditoría judicial.

12 Fuentes y anexos de reproducibilidad

- [1] PREMISA GENERAL DEL PROYECTO (2).pdf, pp. 7–9, Requisitos y rúbrica oficial de Fase 3.
- [2] catedra_fase1/sql/03_ddl_dw.sql y Package.dtsx, DDL del esquema dimensional y paquete SSIS.
- [3] dmd-fase2/notebooks/fase2_dmd_nyc311_ejecutado.ipynb, Ejecución verificada de Árbol CART y K-Means.
- [4] SQL Server DW_NYC311.mining.vw_dataset_fase2 y notebook F2, fuente actual con 1,312,465 filas; el snapshot F2 original se conserva como referencia histórica.
- [5] fase-3/powerbi/sql/validacion_integracion.sql y fase-3/olap/sql, objetos de integración y validación relacional.
- [6] fase-3/powerbi/fuente_pbip, NYC311_Fase3_Final.pbix y build_nyc311_pbir.py, solución Power BI con PBIR y TMDL.
- [7] entrega/defensa (guion_defensa.md y presentacion_fase3_NYC311.pptx), Materiales de defensa oral.
- [8] NYC Mayor's Management Report 2025, https://www.nyc.gov/assets/operations/downloads/pdf/pmmr2025/311.pdf.