UNIVERSIDAD DON BOSCO

Solución analítica para NYC311

Documento final académico | Fase 3

Data Warehouse, minería de datos y Power BI

Asignatura: Data Warehouse y Minería de Datos (DMD104)

Caso de estudio: solicitudes de servicio no urgente NYC311

Período analizado: abril a julio de 2026

Fecha del documento: octubre de 2026

Integrantes

Fernando José Lemus Mejía · LM212528

Gerardo Rafael Bonilla Saz · BS242634

Edson Enrique Chávez Castillo · CC242635

César Giovanni López Ortiz · LO232756

Juan José Galdámez Soto · GS242646

Propósito del documento

Presentar en una sola historia cómo el DW, la minería y el tablero Power BI responden a una pregunta operativa: dónde se concentra la carga de NYC311 y qué señales justifican una revisión temprana.

Resumen ejecutivo

Volver al índice

Este documento presenta la solución final del proyecto NYC311. La Fase 1 organizó las solicitudes en un Data Warehouse dimensional; la Fase 2 aplicó un árbol de decisión y K-Means sobre una vista derivada del DW; la Fase 3 llevó esos resultados a un informe interactivo de Power BI. El objetivo no es sustituir el criterio de las agencias, sino ofrecer una vista consistente para comparar volumen, tiempos observados y perfiles operativos.

El universo de referencia reúne 1,293,816 solicitudes registradas entre abril y julio de 2026. De acuerdo con el informe ejecutado de Fase 2, 63,079 solicitudes no tienen duración observada; se conservan como NULL y no se presentan como demora normal. Para las 1,230,737 solicitudes con tiempo observado, el P75 fue 4,329 minutos (72.2 horas). Este umbral es una regla histórica del período, no un SLA.

La clasificación optimizada reportó Recall de 95.15%, F1 de 78.37% y ROC-AUC de 0.952 en el conjunto de prueba. Es una señal para priorizar revisión humana, no un pronóstico operativo ya desplegado. En la segunda técnica, K-Means se aplicó a perfiles agregados por agency + complaint_type + borough: 480 perfiles elegibles, no a cada solicitud individual. Los tres grupos descritos suman 1,279,792 solicitudes y dejan 14,024 fuera de perfil, categoría que el BI mantiene visible.

> **Conclusión principal**
> El tablero es útil cuando convierte una cifra en una pregunta verificable: qué agencia, territorio o perfil merece revisión y con qué denominador. El resultado económico se presenta únicamente como escenario de horas liberadas; no se afirma ahorro realizado ni causalidad del modelo.

Lectura rápida del resultado

Volver al índice

Evidencia	Lectura que sí permite
1,293,816 solicitudes	Conservar un universo común para el DW, la minería y el tablero.
63,079 sin duración	Separar calidad de datos de demora; no imputar cero.
480 perfiles con K-Means	Comparar comportamientos agregados, sin atribuir un clúster a todos los tickets.
Recall 95.15% en prueba	Evaluar el modelo como filtro de seguimiento; exige validación temporal antes de usarlo en producción.

La trazabilidad se apoya en los informes de Fase 1 y Fase 2, el SQL de integración BI, el PBIX final y su fuente PBIP. Las cifras de modelos se mantienen con su población y unidad de análisis; no se mezclan perfiles con solicitudes.

Índice

Índice estático con enlaces internos. Seleccione un título para ir a la sección correspondiente.

1. Contexto y alcance

2. Fase 1 El Data Warehouse

3. Fase 2 Minería de datos

4. Fase 3 Power BI

5. Costos y escenarios de viabilidad

6. Hallazgos para la gestión

7. Límites y controles pendientes

8. Conclusiones

9. Fuentes consultadas

Cómo leer las cifras

Las cantidades de solicitudes y métricas de Fase 2 son resultados consignados en el informe académico ejecutado. Las cifras del tablero se comprueban en el modelo y en las medidas del PBIX. Los costos y el ROI se identifican como supuestos de escenario y no como mediciones de una operación real.

1. Contexto y alcance

Volver al índice

NYC311 centraliza solicitudes municipales no urgentes y las deriva a agencias responsables. En este proyecto, el problema analítico es comparar carga de trabajo, tiempos de cierre observados y concentración territorial sin depender de consultas aisladas sobre el registro operativo. La unidad de análisis es la solicitud individual identificada por codigo_solicitud.

La ventana de análisis que llega a la Fase 3 es abril-julio de 2026. La Fase 1 validó la extracción y el modelado dimensional con una ventana inicial; la vista de minería y el informe final usan el universo de cuatro meses documentado en Fase 2. Esta distinción evita presentar la primera carga de prueba como si fuera toda la población final.

Preguntas que responde el entregable

Volver al índice

- ¿Dónde se concentra el volumen de solicitudes y cómo cambia entre abril y julio?
- ¿Qué agencias, boroughs y canales muestran mayores tiempos observados o carga relativa?
- ¿Qué perfiles operativos se distinguen por volumen, demora y falta de cierre?
- ¿Qué evidencia permite priorizar una revisión sin confundir asociación con causa?

Alcance que no se afirma

Volver al índice

El proyecto no demuestra que una agencia cause una demora, no convierte el P75 en un compromiso de servicio y no presenta predicciones por solicitud si no existe un score persistido y fechado. Tampoco interpreta una solicitud sin duración como una demora normal. Estas condiciones se mantienen en el BI y en la lectura de resultados.

> **Criterio de lectura**
> Una cifra sólo es comparable si conserva su población, período, unidad y denominador. Por eso el documento separa solicitudes, tiempos observados, perfiles y escenarios monetarios.

2. Fase 1 El Data Warehouse

Volver al índice

La Fase 1 construyó la capa estable para integrar el registro de NYC311. La fuente es el conjunto oficial 311 Service Requests from 2020 to Present de NYC Open Data, identificado como erm2-nwe9. El flujo ETL con SSIS pasa por capas raw y staging antes de cargar el esquema estrella en SQL Server DW_NYC311.

Grano y modelo dimensional

Volver al índice

dw.FactSolicitud conserva una fila por solicitud y utiliza codigo_solicitud como identificador de negocio. Las claves subrogadas conectan el hecho con las dimensiones de fecha, agencia, problema, geografía, estado y canal. minutos_resolucion se calcula cuando las fechas son válidas; puede ser NULL cuando no existe cierre observado.

Objeto	Grano o función	Uso en el análisis
dw.FactSolicitud	1 fila por solicitud	Volumen y duración observada.
DimFecha	1 fila por fecha	Creación y cierre, con roles de fecha.
DimAgencia	1 agencia	Responsable institucional.
DimProblema	1 tipo de problema	Clasificación del incidente.
DimGeografia	1 combinación territorial	Borough y localización.
DimEstado / DimCanal	1 estado / 1 canal	Situación y medio de entrada.

ETL y controles de calidad

Volver al índice

El proceso extrae por API SODA en lotes, conserva una copia cruda, tipa fechas y atributos, separa rechazos y resuelve las llaves de las dimensiones antes de cargar el hecho. La regla de cardinalidad es central: el modelo no debe multiplicar solicitudes al incorporar dimensiones o resultados de minería.

- Identificador único de negocio para evitar duplicados en el hecho.
- Fechas de creación y cierre con validación cronológica.
- Duración en minutos sólo cuando la observación es válida.
- Dimensión de fecha reutilizable para diferenciar creación y cierre.

> **Transición hacia Fase 2**
> La minería no vuelve a consultar la fuente operativa: parte de mining.vw_dataset_fase2, una vista sobre el DW y sus dimensiones. Así, las reglas de grano y calidad se mantienen entre fases.

3. Fase 2 Minería de datos

Volver al índice

La Fase 2 aplica KDD sobre 1,293,816 solicitudes. La etiqueta demora_alta se construye con el P75 de minutos_resolucion: 1 si la duración supera 4,329 minutos, 0 si es menor o igual y NULL si no hay duración. El cálculo se realizó sobre 1,230,737 solicitudes con tiempo final observado; 63,079 quedan sin clasificar.

Árbol de decisión para priorización

Volver al índice

El clasificador utiliza agency, complaint_type, borough, open_data_channel_type, mes y dia_semana como predictores. Se excluyen duración, estado, identificador y coordenadas para evitar usar información posterior al cierre o sin utilidad para el experimento. La partición fue 80/20 con estratificación y semilla 42; las métricas siguientes pertenecen al conjunto de prueba.

Métrica	Resultado	Qué permite decir
Recall	95.15%	Detectó 58,549 de 61,531 demoras reales en prueba.
Precisión	66.63%	Una parte relevante de las alertas fue normal; requiere revisión.
F1	78.37%	Equilibra recall y precisión del modelo evaluado.
ROC-AUC	0.952	Ordena el riesgo en el conjunto de prueba.

El resultado es un filtro de priorización, no una decisión automática. Las 2,982 demoras no detectadas y las 29,328 alertas que terminaron siendo normales muestran por qué la revisión humana y una validación temporal son necesarias antes de una adopción operativa.

K-Means sobre perfiles operativos

Volver al índice

K-Means no agrupa individualmente cada ticket. Primero se agregan solicitudes por la terna agency + complaint_type + borough y se filtran perfiles con al menos 100 solicitudes y métricas válidas. De 912 perfiles iniciales, 487 pasan el mínimo de volumen y 480 se modelan con K=3, log1p y StandardScaler. El mejor Silhouette reportado es 0.421321: separación moderada, útil para explorar prioridades, no una frontera absoluta.

Grupo descriptivo	Perfiles	Solicitudes	Mediana	Porcentaje entre perfiles
Resolución rápida y baja demora	206	899,050	143 min	Demora 8.94% · sin resolver 1.32%
Resolución prolongada y alta demora	245	351,275	11,376 min	Demora 71.09% · sin resolver 6.09%
Rezago crítico y alta proporción sin resolver	29	29,467	33,150 min	Demora 79.10% · sin resolver 82.72%
Fuera de perfil K-Means	No aplica	14,024	No asignado	No se calcula

Los porcentajes de los tres primeros renglones son promedios entre perfiles del informe de Fase 2; no se presentan como tasas globales ponderadas de tickets. La suma de los grupos modelados más los casos fuera de perfil cuadra con el universo documentado.

Lectura operativa

El grupo prolongado combina volumen y demora y por ello justifica una revisión de procesos. El grupo crítico es menor, pero su alta proporción sin resolución exige auditar cierres y estados antes de comparar tiempos.

4. Fase 3 Power BI

Volver al índice

La Fase 3 expone la cadena DW → minería → BI en un informe Power BI final. La vista bi.vw_solicitudes_segmentadas parte de mining.vw_dataset_fase2 y aplica un LEFT JOIN con bi.PerfilCluster por la terna completa, incluyendo el caso nulo de borough. La etiqueta Sin perfil K-Means mantiene visibles las 14,024 solicitudes que no pertenecen a los perfiles elegibles.

Preguntas y páginas del tablero

Volver al índice

Página	Pregunta	Lectura disponible
Panorama de atención ciudadana	¿Dónde está la carga y cuánto tarda?	KPIs, tendencia mensual, carga por borough y filtros.
Dónde concentrar capacidad	¿En qué agencias, boroughs y canales se concentra el problema?	Medianas observadas, canales de entrada y estados.
Segmentación y valor operativo	¿Qué perfiles requieren atención y cómo se sigue la capacidad?	Filtro Sin perfil K-Means, lectura de CART y acciones sobre horas, cuadrillas, backlog y equidad.

Demostración en vivo

El PBIX final se abre en Power BI Desktop para recorrer las tres páginas a escala completa. En la tercera página se prueba el filtro Sin perfil K-Means y se comprueba la cobertura de 14,024 solicitudes; no se incrusta una captura histórica que pueda confundirse con la versión final del informe.

Lectura de las tres páginas

Volver al índice

Página	Elementos que debe mostrar la demo	Decisión que habilita
Panorama ciudadano	1,293,816 solicitudes, mediana observada, demora alta, sin duración, tendencia y carga por borough.	Ubicar volumen y separar tiempo observado de calidad de dato.
Dónde concentrar capacidad	Agencia, borough, canal, estado y medianas observadas; 63,079 NULL se mantienen fuera de la mediana.	Comparar capacidad relativa sin convertir asociación en causa.
Segmentación y valor operativo	480 perfiles K-Means, regla CART, 14,024 fuera de perfil y medidas para horas, cuadrillas, backlog y equidad.	Priorizar revisión humana y medir mejoras operativas antes/después.

Integración y medidas

Volver al índice

El modelo semántico usa la vista de integración como tabla de consumo del informe. Las medidas principales cuentan solicitudes distintas, separan con tiempo y sin duración, calculan demora alta sobre el denominador observado y exponen solicitudes segmentadas frente a fuera de perfil. Esta separación evita sumar perfiles como si fueran tickets y evita reemplazar NULL por cero.

Medida	Definición de lectura
Solicitudes distintas	DISTINCTCOUNT de codigo_solicitud.
Solicitudes con tiempo	Casos cuyo minutos_resolucion no es NULL.
Solicitudes sin duración	Casos cuyo minutos_resolucion es NULL.
Tasa de demora alta	Demoras altas / solicitudes con tiempo observado.
Mediana minutos observados	Mediana de minutos_resolucion, sin imputación.
Solicitudes fuera de perfil	Casos sin coincidencia en la terna de perfiles K-Means.

Control de integración

La comprobación que debe mantenerse en el entorno real es COUNT(*) = COUNT(DISTINCT codigo_solicitud) en la vista BI y la suma de segmentadas + fuera de perfil = total. El documento no sustituye una actualización contra el SQL Server del entorno de ejecución.

5. Costos y escenarios de viabilidad

Volver al índice

Los costos de esta sección son escenarios transparentes para evaluar viabilidad, no facturas ni ahorros observados. Se separan las horas de trabajo, la operación, la licencia para compartir y la infraestructura. El prototipo académico se construyó sobre recursos locales; una puesta en producción requeriría cotizar servidor, respaldos, seguridad y modalidad de publicación.

Base de costos

Volver al índice

Bloque	Supuesto o dato de referencia	Periodicidad	Monto de escenario
Desarrollo	280 h × US$15/h	Inicial	US$4,200
Operación y soporte	10 h/mes × US$15/h	Anual	US$1,800
Power BI Pro	US$14 usuario/mes × 5 usuarios; precio de lista consultado 25/10/2026	Anual	US$840
Infraestructura SQL	Prototipo local: sin costo incremental medido; producción: cotizar	Anual	Variable

Costo conocido a tres años antes de infraestructura productiva: US$4,200 iniciales + 3 × (US$1,800 de operación y US$840 de licencias) = US$12,120. El precio de Power BI es orientativo, puede variar por país, educación y modalidad de contratación; Desktop se usa para autoría, mientras que compartir contenido requiere revisar licenciamiento.

Escenarios de beneficio y ROI

Volver al índice

Para evitar atribuir causalidad al modelo, el beneficio se expresa como horas de análisis liberadas: beneficio anual = horas semanales evitadas × 52 × US$18/h. El siguiente cálculo usa el costo conocido de US$12,120 y supone infraestructura incremental igual a cero; al agregar infraestructura, el denominador aumenta y el ROI disminuye.

Escenario	Horas evitadas/semana	Beneficio 3 años	Beneficio neto antes de infra.	ROI antes de infra.
Bajo	8	US$22,464	US$10,344	85.3%
Base	16	US$44,928	US$32,808	270.7%
Alto	24	US$67,392	US$55,272	456.0%

El ROI anterior es un resultado matemático de supuestos. No significa que el árbol ahorre dinero, que el clúster reduzca tiempos ni que NYC311 haya adoptado el tablero. Para decidir, la organización debería medir primero horas de reportería, frecuencia de reprocesos, adopción y costo real de infraestructura; después comparar una línea base con el uso del BI.

Punto de equilibrio del escenario base

Con los supuestos anteriores, US$12,120 / (16 × 52 × US$18) equivale a aproximadamente 9.7 meses de horas liberadas. El valor cambia si se incorporan infraestructura, más licencias o una tarifa distinta; por eso se reporta como sensibilidad, no como promesa.

6. Hallazgos para la gestión

Volver al índice

Los hallazgos siguientes enlazan una métrica con una acción que puede comprobarse. No son instrucciones para reasignar recursos de forma automática ni conclusiones causales.

Hallazgo	Evidencia	Decisión que se puede evaluar
La demora alta se concentra en una cuarta parte de los casos con tiempo	P75 = 4,329 min; 307,656 demoras altas observadas.	Definir una revisión temprana y medir si reduce el tiempo de análisis.
El grupo prolongado tiene volumen suficiente	351,275 solicitudes en 245 perfiles.	Priorizar revisión de procesos en perfiles de alto volumen.
El grupo crítico tiene mala cobertura de cierre	82.72% sin resolución observada entre perfiles.	Auditar estados y cierres antes de comparar rendimiento.
La clasificación detecta la mayoría de demoras en prueba	Recall 95.15%; precisión 66.63%.	Usar como filtro con revisión humana y validación temporal.
Una parte del universo no tiene perfil K-Means	14,024 solicitudes fuera de perfil.	Mantener la categoría visible y explicar la cobertura del modelo.

Ventaja analítica aportada

Volver al índice

El valor de la solución está en unir tres vistas sin cambiar el grano: el DW aporta consistencia histórica, el árbol aporta una señal de priorización evaluada en prueba y K-Means aporta una segmentación de perfiles. Power BI permite explorar esas capas con filtros y una narrativa operativa. La ventaja no es una cifra aislada, sino reducir el trabajo de reconstruir el mismo corte desde fuentes inconexas.

7. Límites y controles pendientes

Volver al índice

La solución debe leerse con límites explícitos. Estos límites no invalidan el proyecto; indican qué debe comprobarse antes de usarlo como instrumento operativo.

Límite	Riesgo de interpretación	Control recomendado
Ventana abril-julio 2026	Puede no representar un año completo ni otra estación.	Repetir con una partición temporal y comparar períodos.
P75 calculado sobre este período	No es SLA ni umbral universal.	Fijar o recalcular el corte con fecha de vigencia documentada.
Solicitudes sin duración	Imputarlas a cero ocultaría falta de cierre.	Mantener NULL y reportar su denominador por separado.
Árbol medido en prueba aleatoria	No prueba generalización temporal ni producción.	Validar con un período futuro y registrar versión de score.
K-Means sobre perfiles	No asigna automáticamente cada ticket ni prueba causas.	Mostrar cobertura y mantener Sin perfil K-Means.
ROI no observado	Un cálculo positivo puede parecer ahorro realizado.	Medir horas, adopción y costos reales antes de atribuir beneficio.

Regla de integridad

No se debe corregir una cifra para que el tablero cuadre. Si una actualización cambia la cardinalidad, el período o la cobertura de perfiles, se documenta la diferencia antes de presentar resultados.

8. Conclusiones

Volver al índice

El proyecto entrega una cadena coherente desde NYC Open Data hasta Power BI. La Fase 1 establece un hecho con una fila por solicitud y dimensiones para tiempo, agencia, problema, geografía, estado y canal. La Fase 2 conserva el vínculo con ese hecho: etiqueta la demora con un P75 histórico, evalúa un árbol con datos de prueba y agrupa perfiles operativos sin confundirlos con tickets individuales. La Fase 3 presenta esas lecturas en un informe interactivo con cobertura explícita.

La recomendación académica es adoptar el tablero como instrumento de revisión y aprendizaje, no como mecanismo automático de asignación. El primer uso debería concentrarse en el grupo de resolución prolongada, auditar la calidad de los cierres del rezago crítico y medir si el BI reduce horas de reportería. Cualquier ampliación debe repetir el control de cardinalidad, actualizar el período y validar el modelo con datos futuros.

En términos de viabilidad, existe una hipótesis económica razonable si el equipo realmente libera horas de análisis; sin embargo, el ROI permanece en el nivel de escenario hasta que se conozcan la infraestructura de producción, el licenciamiento aplicable y la adopción efectiva. La decisión responsable es medir primero y atribuir después.

9. Fuentes consultadas

Volver al índice

Las fuentes se presentan por nombre y propósito para facilitar la revisión humana. Las cifras del proyecto se tomaron de los informes académicos del grupo y de los artefactos SQL y Power BI entregados; las fuentes externas sustentan el conjunto de datos, las herramientas y la licencia orientativa.

- **Premisa general del proyecto.** Requisitos y rúbrica de Fase 3, especialmente las páginas 7–9. Documento proporcionado por la asignatura.
- **NYC Open Data. 311 Service Requests from 2020 to Present.** Conjunto erm2-nwe9, fuente oficial de solicitudes NYC311. Enlace oficial
- **Microsoft Learn. SQL Server Integration Services.** Referencia de la tecnología ETL utilizada en Fase 1. Enlace oficial
- **Scikit-learn. OneHotEncoder, GridSearchCV y Clustering.** Documentación de las transformaciones, evaluación y K-Means de Fase 2. Enlace oficial
- **Microsoft. Power BI pricing.** Precio orientativo de Power BI Pro consultado el 25 de octubre de 2026; la página advierte variación por moneda, país y modalidad. Enlace oficial
- **Informe académico de Fase 1 del grupo.** Modelo dimensional, grano de FactSolicitud y proceso ETL.
- **Informe académico ejecutado de Fase 2 del grupo.** Universo, P75, métricas del árbol, perfiles K-Means y límites metodológicos.
- **Entrega Power BI final del proyecto.** PBIX, medidas, vista de integración BI y definición PBIP de las tres páginas del informe.

Nota de reproducibilidad

Volver al índice

La revisión final debe abrir el PBIX en Power BI Desktop, comprobar la tabla de integración, actualizar la conexión disponible y repetir las comprobaciones de cardinalidad y cobertura. El PDF que acompaña este documento sirve para revisar redacción y composición; la interacción continúa siendo responsabilidad del informe Power BI.