UNIVERSIDAD DON BOSCO — FACULTAD DE ESTUDIOS DE POSTGRADOS

Data Warehouse y Minería de Datos (DMD104) · Fase 3

Solución Integral de Inteligencia de Negocios y Minería de Datos: NYC311

Integración analítica extremo a extremo: Esquema estrella SQL Server, Minería KDD (Árbol CART + K-Means) y Capa de Presentación Interactiva en Power BI.

INTEGRANTES DEL EQUIPO:

- Lemus Mejía, Fernando José (LM212528)
- Bonilla Saz, Gerardo Rafael (BS242634)
- Chávez Castillo, Edson Enrique (CC242635)
- López Ortiz, César Giovanni (LO232756)
- Galdámez Soto, Juan José (GS242646)

Docente: Ing. Díaz Campos | BI actual: enero y abril–julio 2026 | F2 original: abril–julio 2026 | Noviembre 2026

1. Problema de Negocio y Alcance Operativo de NYC311

00:00–02:00

El reto: priorizar carga masiva heterogénea y distinguir demoras críticas sin distorsionar los datos.

CONTEXTO NYC311

• Sistema centralizado de atención ciudadana no urgente de la Ciudad de Nueva York.

• Universo BI actual: 1,312,465 solicitudes disponibles entre enero y julio de 2026 (enero y abril–julio).

• Alta dispersión geográfica (5 boroughs) y operativa (más de 20 agencias ejecutoras).

• Canales múltiples: Teléfono 311, portal Web, Mobile App y Open Data API.

PROBLEMA OPERATIVO

• Incapacidad de priorizar preventivamente: las demoras se detectan cuando ya vencieron.

• Asimetría severa en tiempos: la mediana global actual es 330 min (~5.5 h), pero el P75 histórico alcanza 4,329 min (~72.2 h).

• Problema de calidad analítica: 63,467 solicitudes actuales carecen de fecha de cierre observada.

• Riesgo de sesgo: imputar duración cero o normal distorsionaría la gestión pública.

OBJETIVO FASE 3

• Construir un tablero analítico en Power BI conectado directamente al DW SQL Server.

• Consumir los 481 perfiles de la publicación BI actual sin perder el grano individual; el snapshot F2 original tuvo 480.

• Aislar de forma transparente los 14,310 casos actuales fuera de clúster y las 63,467 solicitudes sin duración.

• Demostrar viabilidad y retorno operativo con escenarios transparentes y defendibles.

2. Arquitectura de Datos y Linaje Extremo a Extremo

Trazabilidad técnica desde la API oficial de NYC hasta el modelo semántico en Power BI.

02:00–04:00

1. INGESTA Y STAGING

- NYC Open Data (erm2-nwe9)
- Extracción periódica JSON/CSV
- Carga a raw.Solicitud y stg.Solicitud
- Paquete SSIS de Fase 1

2. DATA WAREHOUSE

- SQL Server DW_NYC311
- Fact: dw.FactSolicitud (1.29M filas)
- 6 Dimensiones con llaves subrogadas
- Grano estricto: 1 fila por solicitud

3. MINERÍA (KDD)

- Vista mining.vw_dataset_fase2
- Árbol CART (Recall 95.15% en test F2)
- K-Means actual (481 perfiles, K=3)
- Persistencia en bi.PerfilCluster

4. PRESENTACIÓN BI

- Vista bi.vw_solicitudes_segmentadas
- Power BI Desktop (Modo Import)
- PBIP + PBIR + TMDL (Git nativo)
- 3 Páginas interactivas validadas

REGLA DE INTEGRIDAD: No existen CSVs sueltos ni datos desconectados. El Dashboard consume exclusivamente la vista SQL bi.vw_solicitudes_segmentadas, reconciliando exactamente 1,312,465 registros en todas las capas.

3. Fase 1: Modelo Dimensional y Esquema Estrella

Estructura analítica en SQL Server diseñada para soportar consultas analíticas de alto rendimiento.

04:00–05:30

TABLA DE HECHOS CENTRAL: dw.FactSolicitud

- Grano: Exactamente una fila por cada solicitud de servicio recibida.
- Identificador: codigo_solicitud único (UQ_FactSolicitud).
- Medida analítica principal: minutos_resolucion (Duración en minutos desde creación hasta cierre).
- Tratamiento de Nulos: minutos_resolucion es NULL si la solicitud sigue abierta. No se imputa a cero.
- Coordenadas: latitude y longitude para agregación y mapeo geoespacial.
- Llaves foráneas hacia 6 dimensiones con integridad referencial garantizada.

TABLAS DE DIMENSIONES (6 EJES DE ANÁLISIS)

- dw.DimFecha: fecha_key (YYYYMMDD), año, mes, día, día de semana. Rol dual creación / cierre.
- dw.DimAgencia: agencia_key, acrónimo de agencia (NYPD, HPD, DOT, DSNY) y nombre oficial.
- dw.DimProblema: problema_key, complaint_type, descriptor operativo y sub-descriptor.
- dw.DimGeografia: geografia_key, borough (5 distritos), ZIP code, community board y precinto.
- dw.DimEstado: estado_key, status operativo (Closed, Open, Pending, In Progress, Assigned).
- dw.DimCanal: canal_key, open_data_channel_type (Phone, Online, Mobile, Other, Unknown).

4. Fase 1: Proceso ETL y Garantía de Calidad

Extracción, estandarización de catálogos y generación de llaves subrogadas con SSIS.

05:30–07:00

1. EXTRACCIÓN (Extract)

- Descarga estructurada desde NYC Open Data mediante endpoint REST erm2-nwe9.
- Carga cruda inicial hacia schema raw.Solicitud.
- Captura de campos temporales, geográficos, categorización y estado administrativo.

2. TRANSFORMACIÓN (Transform)

- Limpieza de inconsistencias textuales y colaciones en nombres de agencia y borough.
- Normalización de coordenadas espaciales anómalas fuera del rango de NYC.
- Cálculo derivado de minutos_resolucion = DATEDIFF(minute, created_date, closed_date).
- Mapeo de llaves de negocio a dimensiones conformadas (Surrogate Keys).

3. CARGA (Load)

- Poblado masivo con SSIS Package.dtsx aplicando inserción en bloques optimizada.
- Manejo estricto de duplicados mediante UQ_FactSolicitud en dw.FactSolicitud.
- Comprobación de cuadratura: 1,312,465 registros cargados exitosamente.

EVIDENCIA TÉCNICA: Código SSIS disponible en catedra_fase1/Package.dtsx y scripts DDL en sql/03_ddl_dw.sql. En defensa se presenta la traza de ejecución fechada y verificación de conteos.

5. Fase 2: Minería Predictiva — Árbol de Clasificación (CART)

07:00–09:30

Detección preventiva temprana de riesgo de demora alta en el momento de creación del ticket.

FORMULACIÓN METODOLÓGICA (KDD)

• Etiqueta objetivo (demora_alta): 1 si minutos_resolucion > P75 (4,329 min / ~72.2 h); 0 si <= P75; NULL si no cerrada.

• Universo de entrenamiento: 1,230,737 casos resueltos (923,081 normales y 307,656 demoras altas).

• Variables predictoras (X): agency, complaint_type, borough, open_data_channel_type, mes, dia_semana.

• Prevención estricta de fuga de datos (Data Leakage): Se excluyen duración, fecha_cierre y status, ya que no existen al momento de radicar el caso.

• Alineación al negocio: En servicio público es prioritario minimizar falsos negativos (casos demorados no detectados).

DESEMPEÑO EN CONJUNTO DE PRUEBA (TEST)

Recall (Sensibilidad): 95.15%
→ Detecta 58,549 de 61,531 demoras críticas reales

F1-Score: 78.37%
→ Equilibrio sólido entre precisión y exhaustividad

ROC-AUC: 0.952
→ Excelente capacidad de discriminación probabilística

Falsos Negativos: 2,982
→ Solo 4.85% de las demoras altas escaparon al modelo

Falsos Positivos: 29,328
→ Alertas preventivas que requirieron revisión

ADVERTENCIA TÉCNICA: Las métricas corresponden a evaluación histórica de prueba; en el dashboard se presentan como contexto explicativo, no como pronósticos en producción.

6. Fase 2: Minería Descriptiva — Segmentación K-Means

09:30–12:00

El snapshot F2 tuvo 480 perfiles; la publicación BI actual reejecuta el pipeline sobre el rango disponible y conserva la trazabilidad.

METODOLOGÍA DE CLUSTERING POR PERFILES OPERATIVOS

K-Means NO se aplicó fila por fila a 1.3M tickets: se construyeron perfiles agregados por (agency + complaint_type + borough). La publicación BI actual obtuvo 481 perfiles elegibles sobre el rango disponible, con K=3, StandardScaler y parámetros reproducibles; el experimento F2 original documentó 480 perfiles y Silhouette 0.421.

Clúster 1: Resolución Rápida y Baja Demora

203 perfiles | 910,529 solicitudes (69.4% del universo)
Mediana duración: 129 min (~2.2 h) | Tasa demora alta: 5.92% | Sin duración: 1.12%
Interpretación: Servicios de resolución relativamente rápida en el rango actual.

Clúster 2: Resolución Prolongada y Alta Demora

249 perfiles | 358,005 solicitudes (27.3% del universo)
Mediana duración: 11,241 min (~7.8 días) | Tasa demora alta: 75.12% | Sin duración: 6.49%
Interpretación: Perfiles de alta demora que requieren revisión de capacidad.

Clúster 3: Rezago Crítico y Alta Proporción Sin Resolver

29 perfiles | 29,621 solicitudes (2.3% del universo)
Mediana duración: 21,277 min (~14.8 días) | Tasa demora alta: 80.26% | Sin duración: 81.65%
Interpretación: Perfiles con rezago y alta falta de cierre observado.

CONTROL DE COBERTURA: 910,529 + 358,005 + 29,621 = 1,298,155 solicitudes segmentadas. Las 14,310 solicitudes restantes se preservan como 'Sin perfil K-Means' (1.09% del total). ¡Ninguna solicitud desaparece del BI!

7. Fase 3: Integración Técnica DW — Minería — Power BI

Diseño relacional de consumo sin dispersión de grano y persistencia de perfiles en SQL Server.

12:00–14:00

OBJETOS DE INTEGRACIÓN EN SQL SERVER

• Tabla bi.PerfilCluster: Almacena los 481 perfiles de la publicación actual, con cluster_id, cluster_nombre, versión de modelo y metadatos.

• Índices Únicos Filtrados: UX_PerfilCluster_TernaNoNula y UX_PerfilCluster_TernaNula garantizan unicidad de la terna (agency, complaint_type, borough).

• Vista bi.vw_solicitudes_segmentadas: Realiza LEFT JOIN nulo-seguro entre mining.vw_dataset_fase2 y bi.PerfilCluster.

• Preservación de Grano: 1,312,465 filas en la vista = 1,312,465 solicitudes distintas. No hay multiplicación ni joins 1:N.

• Bandera es_segmentado: 1 para las 1,298,155 con clúster; 0 para las 14,310 'Sin perfil K-Means'.

MODELO SEMÁNTICO EN POWER BI

• Modo de Conexión: Import: Garantiza estabilidad, velocidad sub-segundo e independencia en la máquina de exposición.

• Medida DAX Solicitudes distintas: DISTINCTCOUNT(codigo_solicitud) = 1,312,465 exactos.

• Medida DAX Tasa demora alta: DIVIDE([Solicitudes demora alta], [Solicitudes con tiempo]). Excluye estrictamente las 63,467 solicitudes sin duración.

• Formato PBIP / PBIR / TMDL: Proyecto versionable en Git con definición modular de visuales y modelo semántico legible.

• Sincronización con Guion: El segmentador de cluster_nombre permite filtrar 'Sin perfil K-Means' y verificar 14,310 casos en vivo.

8. Demostración en Vivo: Dashboard — Páginas 1 y 2

Panorama de atención ciudadana y diagnóstico de capacidad operativa por agencia y distrito.

14:00–17:00

PÁGINA 1: PANORAMA CIUDADANO

• Fila de KPIs: 1,312,465 solicitudes recibidas | Mediana 330 min (~5.5 h) | 313,360 demoras altas observadas | 63,467 sin duración.

• Segmentadores Interactivos: Borough, Agencia, Clúster K-Means y Estado.

• Tendencia Temporal (Mes/Año): Enero y abril–julio 2026, sin agregaciones erróneas de identificadores.

• Carga por Borough: Brooklyn (417k) y Queens (335k) concentran el mayor volumen.

• Mapa Geoespacial: Distribución por distritos urbanos con escala proporcional de burbujas.

• Interacción cruzada: Filtrar una agencia recalcula instantáneamente KPIs y mapa.

PÁGINA 2: DÓNDE CONCENTRAR CAPACIDAD

• Pregunta de Decisión: ¿En qué agencias y zonas se originan los cuellos de botella operativos?

• Mediana por Agencia: DOHMH y HPD presentan medianas superiores a 1,200 min, mientras NYPD resuelve en ~85 min.

• Mediana por Borough: Staten Island y Bronx reflejan tiempos típicos superiores a Manhattan.

• Volumen por Canal de Entrada: El canal Phone (311) domina llamadas iniciales, pero Online/Mobile concentra mayor seguimiento.

• Estado Operativo: 94.8% de solicitudes figuran 'Closed', 4.87% 'Pending/Open', permitiendo auditar backlog.

9. Demostración en Vivo: Dashboard — Página 3 y Segmentación

17:00–19:00

Consumo de los 481 perfiles actuales y contexto predictivo histórico del Árbol CART.

PÁGINA 3: SEGMENTACIÓN DE MINERÍA

• Segmentador de Clústeres F2: Permite alternar entre los 3 grupos y la categoría 'Sin perfil K-Means'.

• Prueba de Cuadratura en Vivo:

• → Al seleccionar 'Sin perfil K-Means', la tarjeta muestra exactamente 14,310 casos.

• → Al seleccionar 'Rezago crítico', se filtran 29,621 solicitudes con mediana de 21,277 min.

• → Al limpiar el filtro, el tablero retorna al total íntegro de 1,312,465.

• Gráfico Comparativo de Mediana por Clúster: Evidencia visual del contraste entre Rápida (129 min) y Rezago (21,277 min).

USABILIDAD PARA LA TOMA DE DECISIONES

• Asignación Preventiva de Cuadrillas: Al identificar reclamos clasificados en perfiles de Rezago Crítico, la agencia reasigna inspectores antes de superar el P75.

• Descongestión de Canales: Permite a los supervisores de distrito auditar qué agencias demoran más de 72 horas.

• Contextualización Metodológica: Los paneles explican las métricas del árbol (Recall 95.15%) y los supuestos de K-Means para evitar que se interpreten como certezas causales.

10. Análisis de Costos, Viabilidad y Retorno Operativo (ROI)

19:00–21:00

Modelo financiero estructurado a 3 años para la gestión pública sin ingresos por ticket.

ESTRUCTURA DE COSTOS (HORIZONTE 3 AÑOS)

- **Desarrollo Inicial (CAPEX): 4,520 USD**
  280 h equipo (15 USD/h) + capacitación
- **Infraestructura Cloud / Servidor: 1,800 USD/año**
  SQL Server / Azure SQL VM (150 USD/mes)
- **Licenciamiento Power BI Pro: 600 USD/año**
  5 usuarios supervisores (10 USD/mes c/u)
- **Soporte y Mantenimiento (OPEX): 1,800 USD/año**
  10 h/mes soporte y reentrenamiento
- **Costo Recurrente Anual: 4,200 USD/año**
  Infraestructura + Licencias + Soporte
- **Costo Total a 3 Años (TCO): 17,120 USD**
  4,520 CAPEX + (3 × 4,200 OPEX)

ESCENARIOS DE BENEFICIO Y RETORNO (ROI)

Escenario Conservador (Bajo)

Ahorro de 8 h/semana entre analistas (416 h/año a 18 USD/h)
Beneficio 3 años: 22,464 USD | Beneficio Neto: 5,344 USD
ROI: 31.2% | Punto de Equilibrio: Mes 28

Escenario Base (Más Probable)

Ahorro de 16 h/semana en consolidación y cruces (832 h/año)
Beneficio 3 años: 44,928 USD | Beneficio Neto: 27,808 USD
ROI: 162.4% | Punto de Equilibrio: Mes 14

Escenario Optimista (Alto)

Ahorro de 24 h/semana + 5% reducción de reprocesos
Beneficio 3 años: 66,000 USD | Beneficio Neto: 48,880 USD
ROI: 285.5% | Punto de Equilibrio: Mes 9

11. Conclusiones, Ética y Sustentación Teórica

Síntesis de aprendizajes, límites del modelo y preparación ante el tribunal evaluador.

21:00–23:00

CONCLUSIONES TÉCNICAS Y OPERATIVAS

• Integración Real: Se logró una solución analítica completa que conecta SQL Server, modelos KDD en Python y Power BI nativo.

• Respeto a la Integridad de Datos: Se preservaron las 63,467 solicitudes actuales sin duración y los 14,310 casos fuera de clúster sin forzar imputaciones artificiales.

• Acción sobre Causalidad: El tablero no prueba causas, pero orienta investigaciones de campo con precisión de datos verificada.

• Valor Ciudadano: Permite una distribución más justa y equitativa de los recursos municipales entre distritos.

DOMINIO TEÓRICO ANTE EL TRIBUNAL

¿Por qué P75 no es SLA?

→ Es un umbral histórico interno derivado del periodo abril–julio 2026 (4,329 min), no un compromiso contractual normativo.

¿Por qué K-Means no agrupó tickets individuales?

→ Porque se modelaron perfiles operativos por agencia+queja+borough; F2 documentó 480 y la publicación BI actual reejecutada conserva 481.

¿Por qué Import y no DirectQuery?

→ Import asegura estabilidad, tiempo de respuesta <1s y autonomía frente a caídas de red durante la defensa oral.

¿El ROI es dinero real ganado?

→ Es una estimación de ahorro en horas y reprocesos en un servicio público, modelado con escenarios transparentes.