Minería de Datos y Descubrimiento de Conocimiento para NYC311

Fase 2 Trazabilidad KDD, Árbol de Decisión y K-Means

Universidad Don Bosco DMD104 Septiembre de 2026



1,293,816 solicitudes

Presentación de defensa

Problema y preguntas de minería

BASE ANALÍTICA

1,293,816

solicitudes de NYC311 entre abril y julio de 2026

PREGUNTA 1

¿Qué solicitudes tienen mayor probabilidad de terminar con demora alta?

Clasificación supervisada con Árbol de Decisión

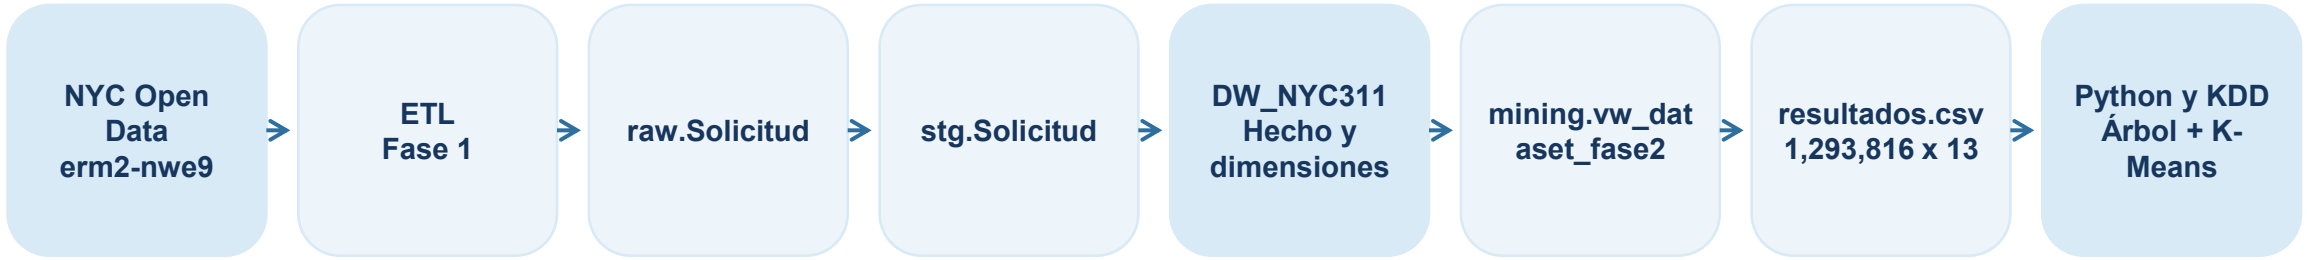
PREGUNTA 2

¿Qué perfiles combinan volumen, demora y falta de resolución?

Agrupación no supervisada con K-Means

Elaboración propia con el notebook ejecutado

Trazabilidad desde la fuente hasta los modelos



La Fase 2 usa el Data Warehouse consolidado. No vuelve a RAW como fuente directa de minería.

La vista conserva una fila por solicitud y conecta cada resultado con su origen.

Fuente externa: NYC Open Data, dataset erm2-nwe9

Vista analítica y origen de las 13 variables

Variables	Procedencia
codigo, minutos, latitud, longitud	dw.FactSolicitud
agency	dw.DimAgencia
complaint_type	dw.DimProblema
borough	dw.DimGeografia
status	dw.DimEstado
open_data_channel_type	dw.DimCanal
año, mes, día de semana	dw.DimFecha
demora_alta	CASE calculado con P75

SQL REAL DE LA VISTA

```
PERCENTILE_CONT(0.75)
WITHIN GROUP (
  ORDER BY minutos_resolucion
)

FactSolicitud
  JOIN DimFecha
  JOIN DimAgencia
  JOIN DimProblema
  LEFT JOIN DimGeografia
  JOIN DimEstado
  LEFT JOIN DimCanal
```

Resultado verificado
1,293,816 solicitudes x 13 variables

Fuente interna: DW_NYC311 y mining.vw_dataset_fase2

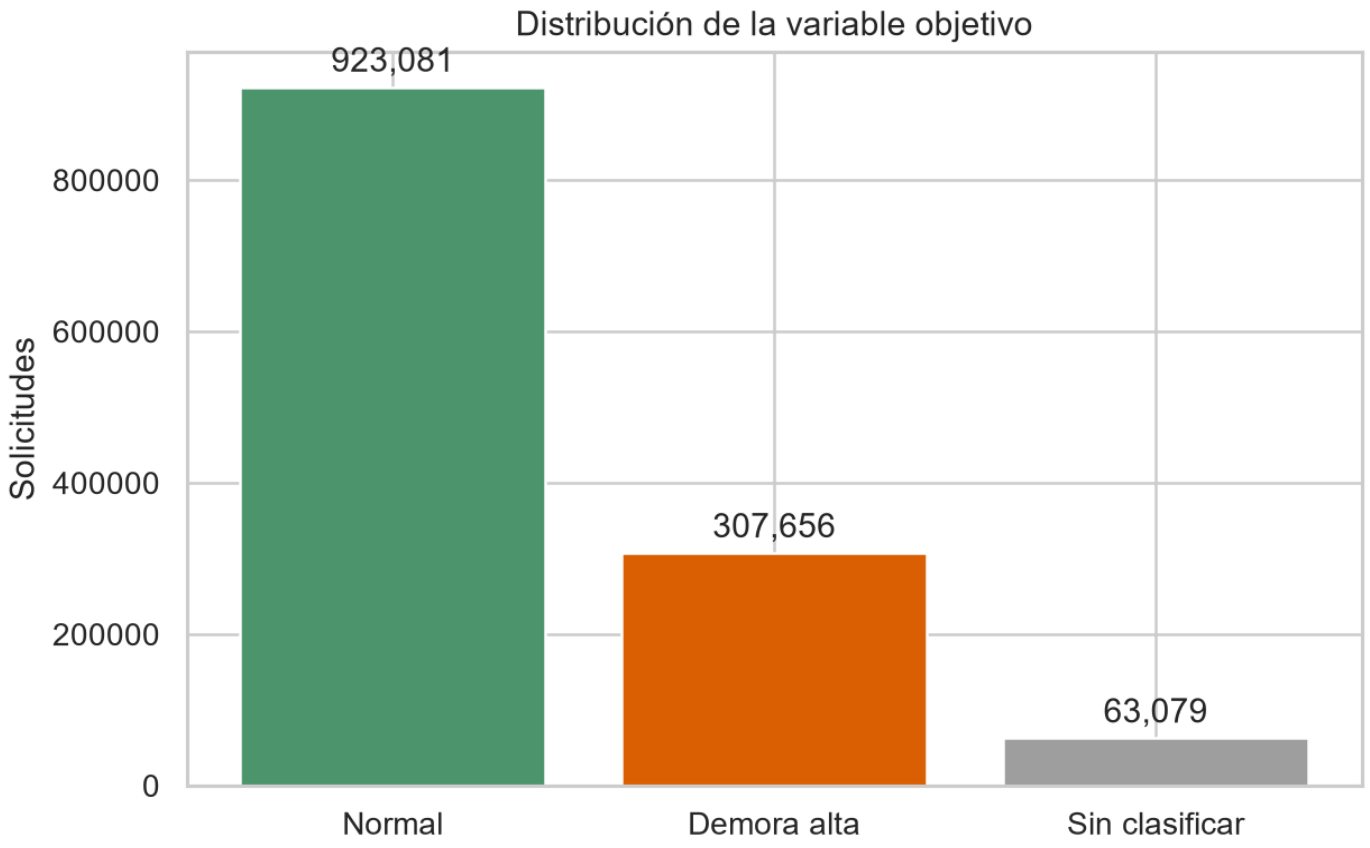
Evidencia del preprocesamiento KDD

Requisito	Qué se hizo	Razón
Selección	Vista del hecho y dimensiones	Conservar 13 variables relevantes
Nulos	63,079 tiempos sin imputar	No existe cierre observado
Discretización	P75 = 4,329 crea demora_alta	Separar el 25% de tiempos mayores
Codificación	OneHotEncoder	Categorías sin orden artificial
Transformación	log1p en volumen y mediana	Reducir asimetría y extremos
Normalización	StandardScaler en K-Means	Comparar distancias en una escala común
Selección final	Se excluyen minutos, estado e ID	Evitar fuga o variables sin aporte

KDD incluye preparación, minería, evaluación e interpretación. Los algoritmos ocupan una etapa del proceso.

Elaboración propia con el notebook ejecutado

Construcción estadística de demora alta



PERCENTILES OBSERVADOS

```
P25        65 min
P50     330 min
P75   4,329 min   corte
P90 21,062 min
P95 43,399 min
P99 90,956 min
```

NYC no entrega la etiqueta demora_alta. El proyecto la crea con el cuartil superior de 1,230,737 tiempos reales.

63,079 casos sin tiempo final permanecen sin clasificar.

Elaboración propia con el notebook ejecutado

Diseño y selección del Árbol de Decisión

DATOS Y PIPELINE

1,230,737 casos clasificables

80% entrenamiento
20% prueba estratificada

OneHotEncoder + Pipeline

random_state = 42

GRIDSEARCHCV

Parámetro	Valores	Elegido
max_depth	6, 10, 15	15
min_samples_leaf	50, 100, 250	50
class_weight	None, balanced	balanced
scoring	F1	0.787 CV

18 combinaciones x 3 folds = 54 ajustes

Control de fuga: minutos_resolucion, status, año e identificador quedan fuera del árbol.

Elaboración propia con el notebook ejecutado

El ajuste eleva el Recall a 95.15 por ciento

95.15%

de las demoras reales fueron detectadas por el modelo optimizado

Modelo	Exactitud	Precisión	Recall	F1	ROC AUC
Base	86.98%	83.79%	59.41%	69.53%	0.922
Optimizado	86.87%	66.63%	95.15%	78.37%	0.952

USO

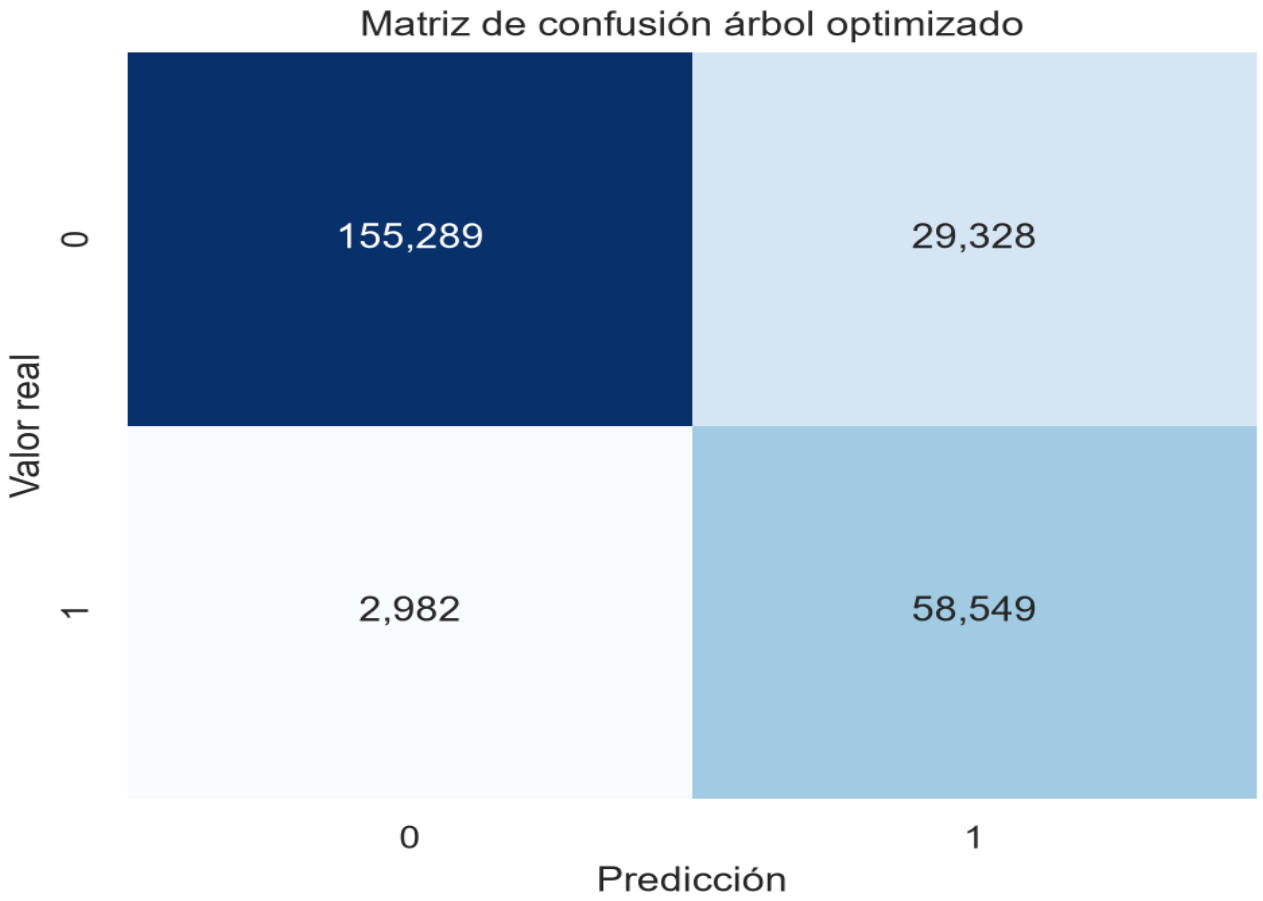
Filtro de priorización con revisión humana.

INTERPRETACIÓN

Los pesos balanceados reducen falsos negativos. La precisión baja porque el modelo produce más alertas preventivas.

Elaboración propia con el notebook ejecutado

Errores y aciertos del árbol optimizado



DEMORAS REALES

58,549

detectadas correctamente

2,982

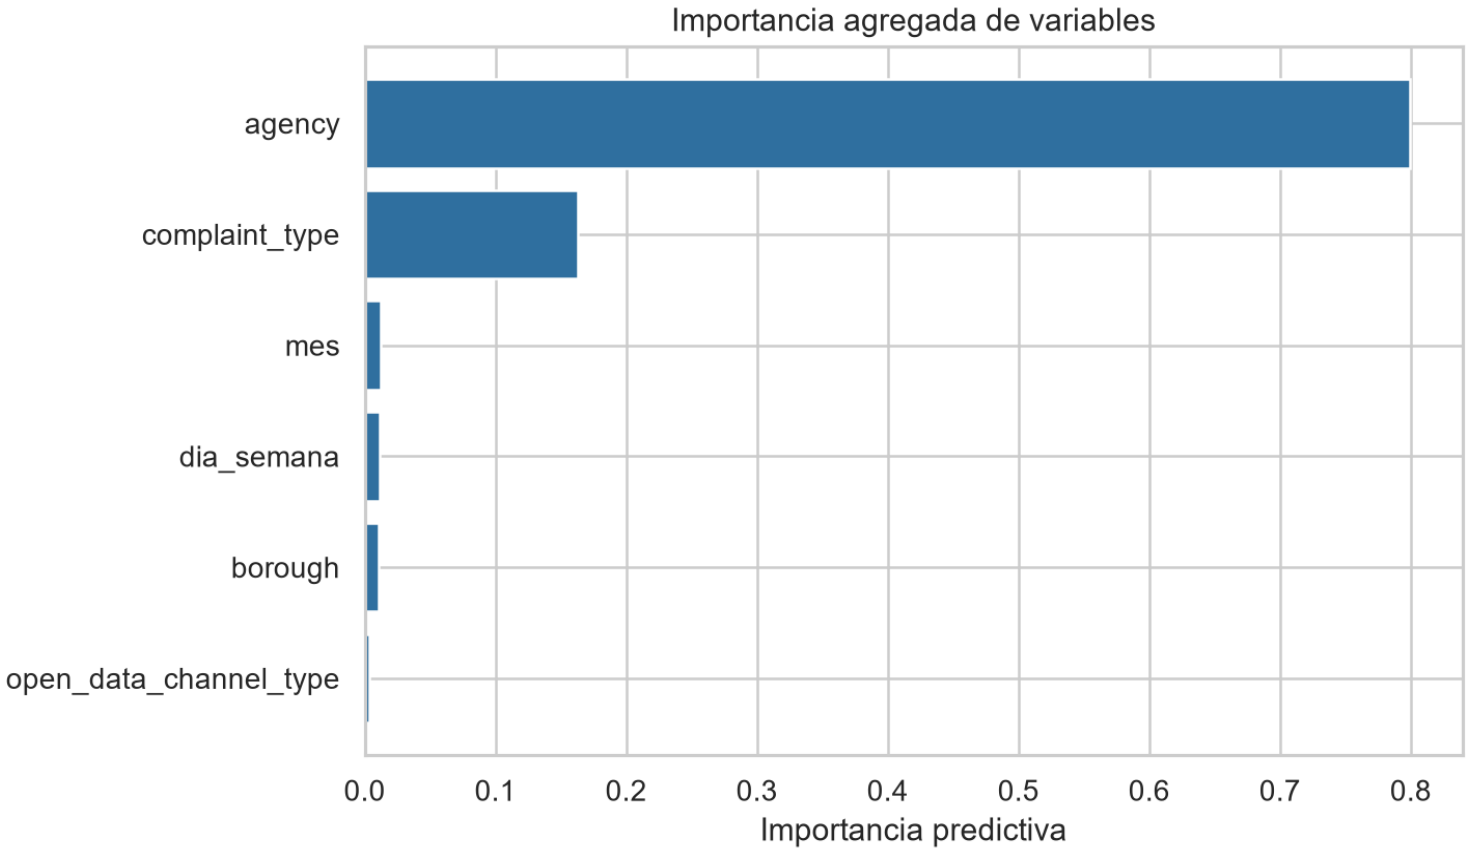
demoras sin alerta

29,328

falsos positivos para revisión

Elaboración propia con el notebook ejecutado

Agencia y tipo de reclamo dominan la predicción



79.95%

importancia agregada de agency

16.27%

importancia agregada de complaint_type

La importancia es predictiva. No demuestra causalidad.

Elaboración propia con el notebook ejecutado

Construcción de perfiles para K-Means

MUCHAS SOLICITUDES

agency	complaint_type	borough
HPD	UNSANITARY CONDITION	BRONX
HPD	UNSANITARY CONDITION	BRONX
HPD	UNSANITARY CONDITION	BRONX
...	...	...

UN PERFIL AGREGADO

HPD + UNSANITARY CONDITION + BRONX

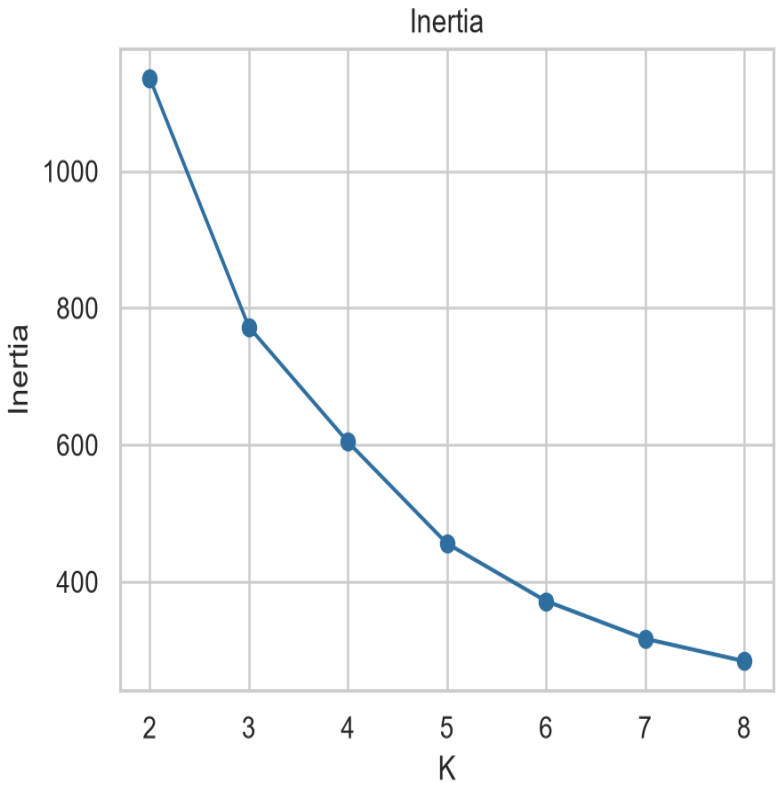
14,286 solicitudes
mediana 13,285 min
89.46% con demora

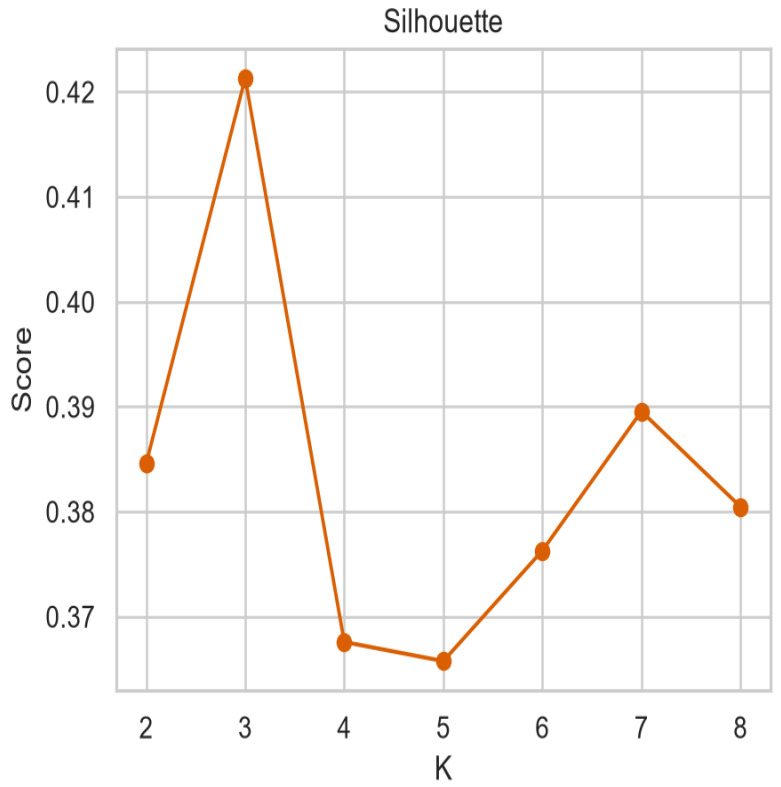
Cada combinación de agencia, tipo de reclamo y borough aporta un registro a K-Means.

912 perfiles originales **487 con al menos 100 solicitudes** **480 perfiles finales**

Elaboración propia con el notebook ejecutado

K igual a 3 ofrece la mejor separación evaluada





0.421

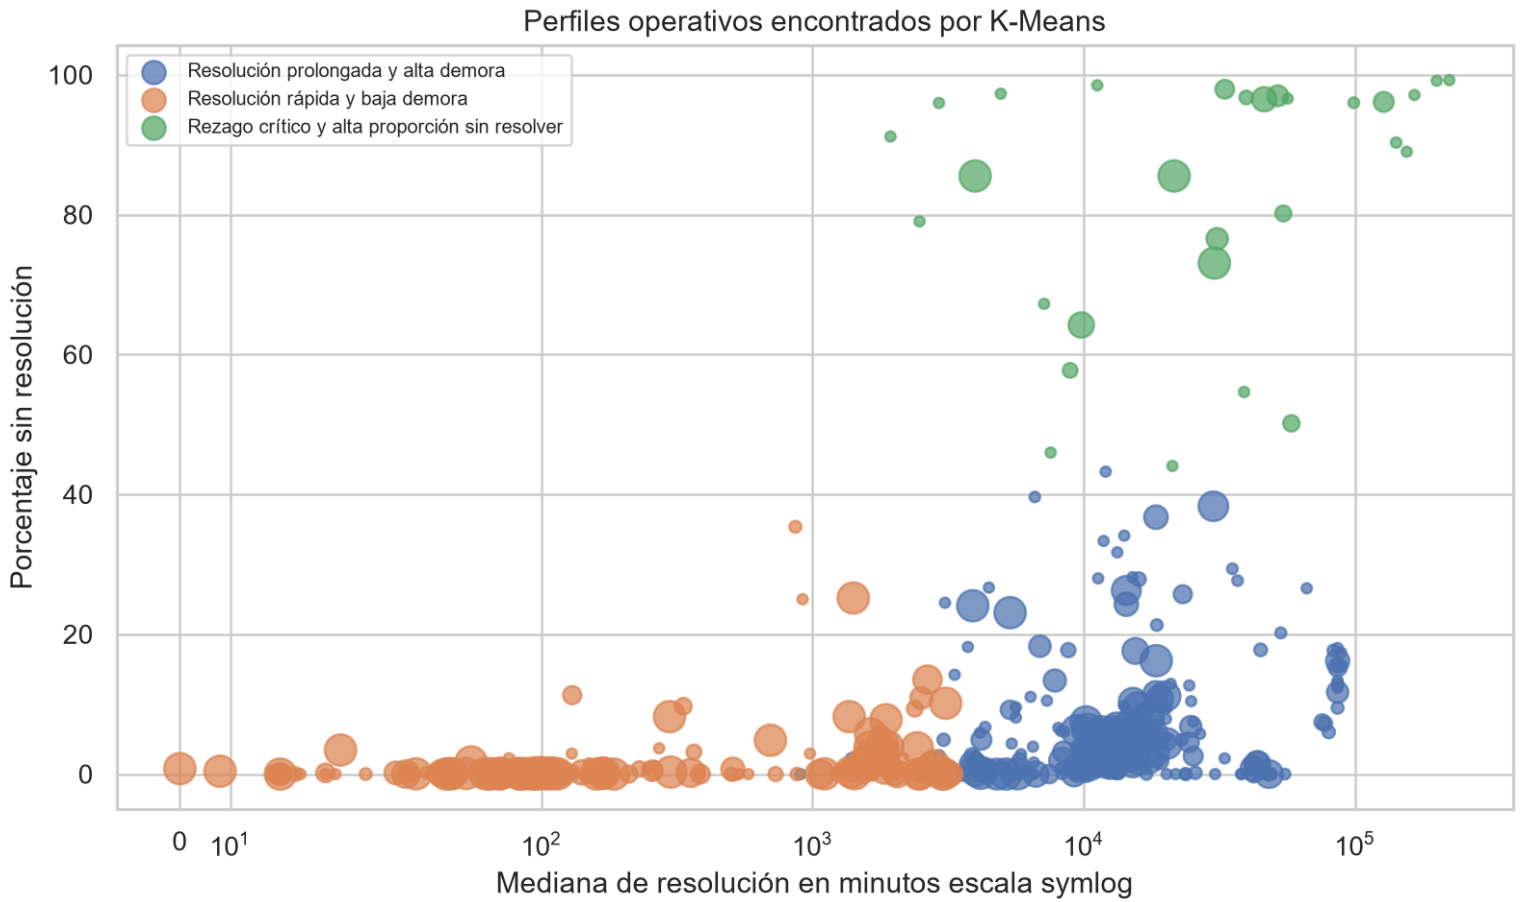
Silhouette para K igual a 3

LECTURA

La separación es moderada. Los grupos permiten explorar prioridades y conservan cierto solapamiento.

Elaboración propia con el notebook ejecutado

Tres perfiles operativos



RESOLUCIÓN RÁPIDA

899,050 solicitudes
143 min de mediana
8.94% con demora

RESOLUCIÓN PROLONGADA

351,275 solicitudes
11,376 min de mediana
71.09% con demora

REZAGO CRÍTICO

29,467 solicitudes
82.72% sin resolución

Elaboración propia con el notebook ejecutado

Conocimiento, uso y límites

USO PROPUESTO

1 Árbol como filtro con revisión humana

2 Perfiles de alto volumen en resolución prolongada

3 Auditoría de estados en el rezago crítico

4 Recálculo del P75 al incorporar meses

LÍMITES DE LA EVIDENCIA

Periodo de abril a julio de 2026

Clase dependiente del P75 observado

Importancia predictiva sin causalidad

Silhouette 0.421 con solapamiento

Casos abiertos sin tiempo final

El análisis ayuda a decidir qué revisar primero y conserva la revisión humana.

Elaboración propia con el notebook ejecutado

Evidencia reproducible y referencias

ARCHIVOS EVALUADOS

Notebook
notebooks/fase2_dmd_nyc311.ipynb

Notebook ejecutado
notebooks/fase2_dmd_nyc311_ejecutado.ipynb

Dataset
tmp/data/resultados.csv

Vista SQL
tmp/codigo/sql/mining_view_fase2.sql

SHA-256 notebook AD1D37D9CAD7
SHA-256 CSV E43B66DD3693

REFERENCIAS

[1] NYC Open Data
311 Service Requests from 2020 to Present
dataset erm2-nwe9

[2] scikit-learn
OneHotEncoder y GridSearchCV

[3] scikit-learn
K-Means, StandardScaler y Silhouette

Tablas y gráficas: elaboración propia con resultados del notebook ejecutado.

Fuentes completas disponibles en las notas y en el informe