DMD104 / UNIVERSIDAD DON BOSCO

NYC311 Fase 3

Del dato abierto a la decisión operativa

Data Warehouse · Minería · Power BI

Defensa · 26 octubre 2026

Lemus Mejía · Bonilla Saz · Chávez Castillo
López Ortiz · Galdámez Soto

NYC 311

1,312,465 solicitudes

BI: enero y abril–julio 2026

F1 → F2 → F3

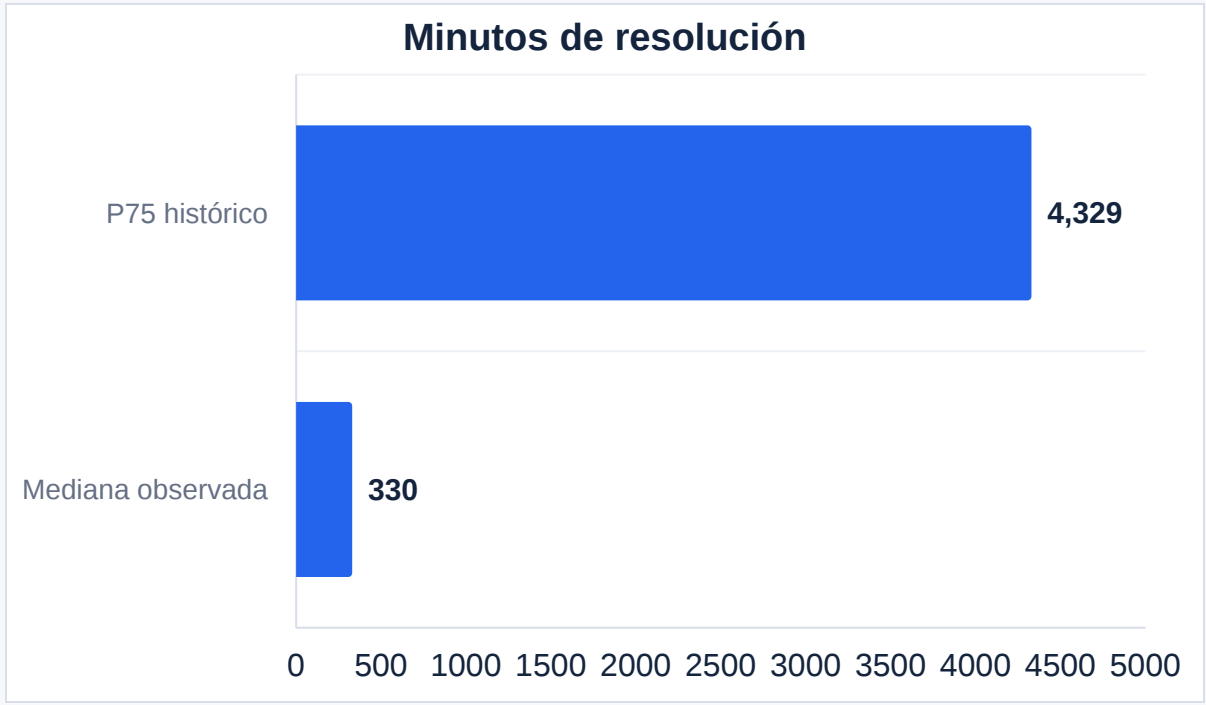
La demora está concentrada y el dato faltante debe quedar visible

BI actual: enero y abril–julio 2026. El snapshot F2 abril–julio se conserva como referencia histórica.

1,312,465
solicitudes en el BI actual

63,467
sin duración observada

El BI actual conserva NULL cuando no existe fecha de cierre. Esos casos quedan fuera de la etiqueta de demora alta.



P75 = 4,329 min
Umbral histórico, no SLA

Fuente: Fase 2 README y validación BI. La mediana se calcula solo con duración observada.

La cuadratura se conserva del DW al tablero

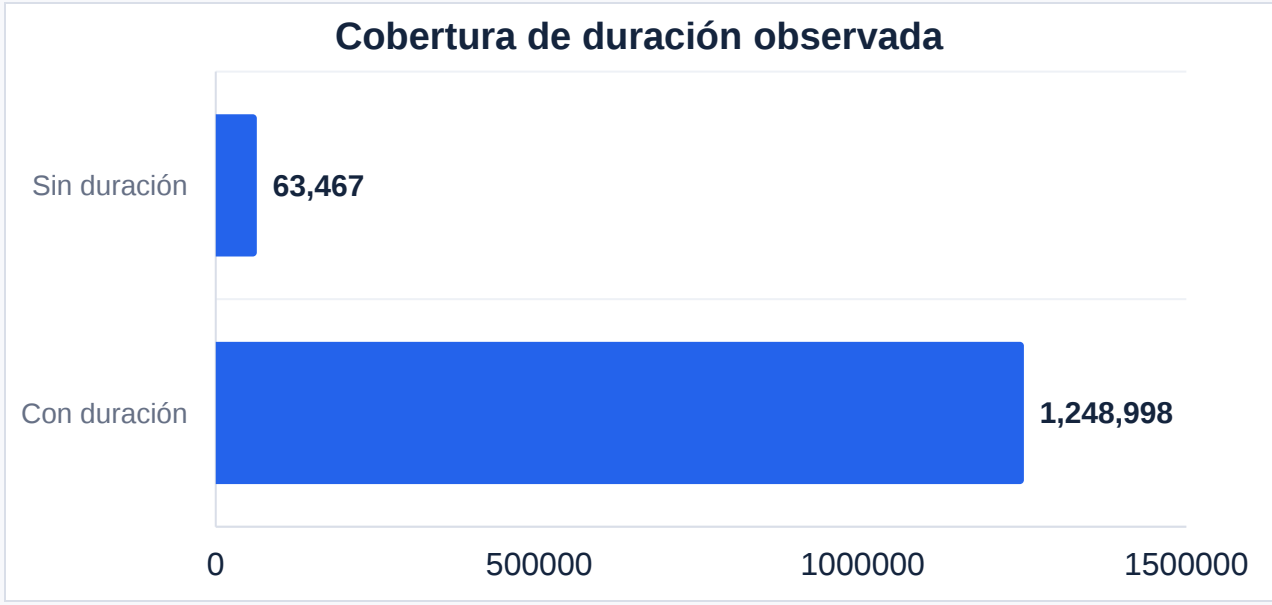
El modelo BI mantiene el grano de una fila por solicitud y el LEFT JOIN no multiplica registros.

1,312,465

DW · minería · vista BI

1 fila = 1 solicitud
Cero multiplicación en la integración

La población con duración observada y la población sin duración suman exactamente el universo.

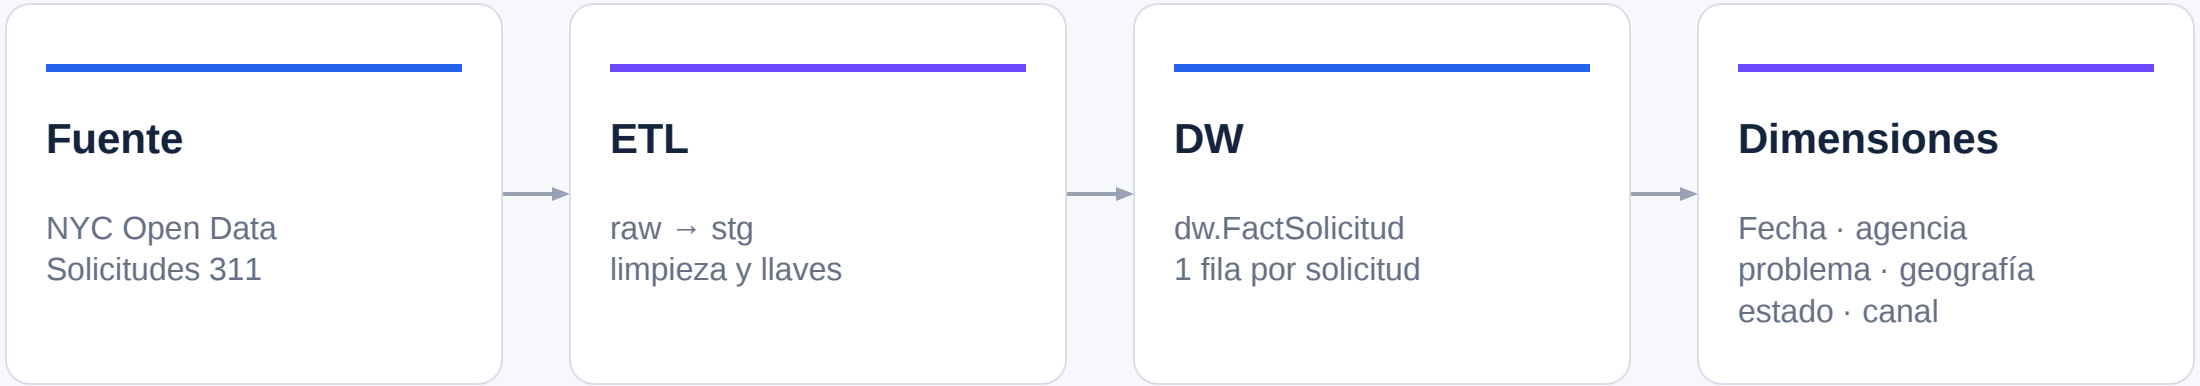


313,360 demoras altas
25.09% entre los 1,248,998 casos con tiempo

Fuente: validación del modelo BI y medidas DAX ejecutadas en VertiPaq.

Arquitectura F1: una cadena de datos con grano explícito

La Fase 1 prepara el hecho dimensional que F2 y F3 consumen sin cambiar la unidad de análisis.



Medida central

minutos_resolucion

NULL cuando no existe fecha de cierre

F2 y F3

mining.vw_dataset_fase2
bi.vw_solicitudes_segmentadas

Unión nulo-segura por agencia + complaint_type + borough

Fuente: Fase 1 DDL/SSIS y docs/02-INTEGRACION-DATOS.md. La conexión BI validada usa SQL Server DW_NYC311 en modo Import.

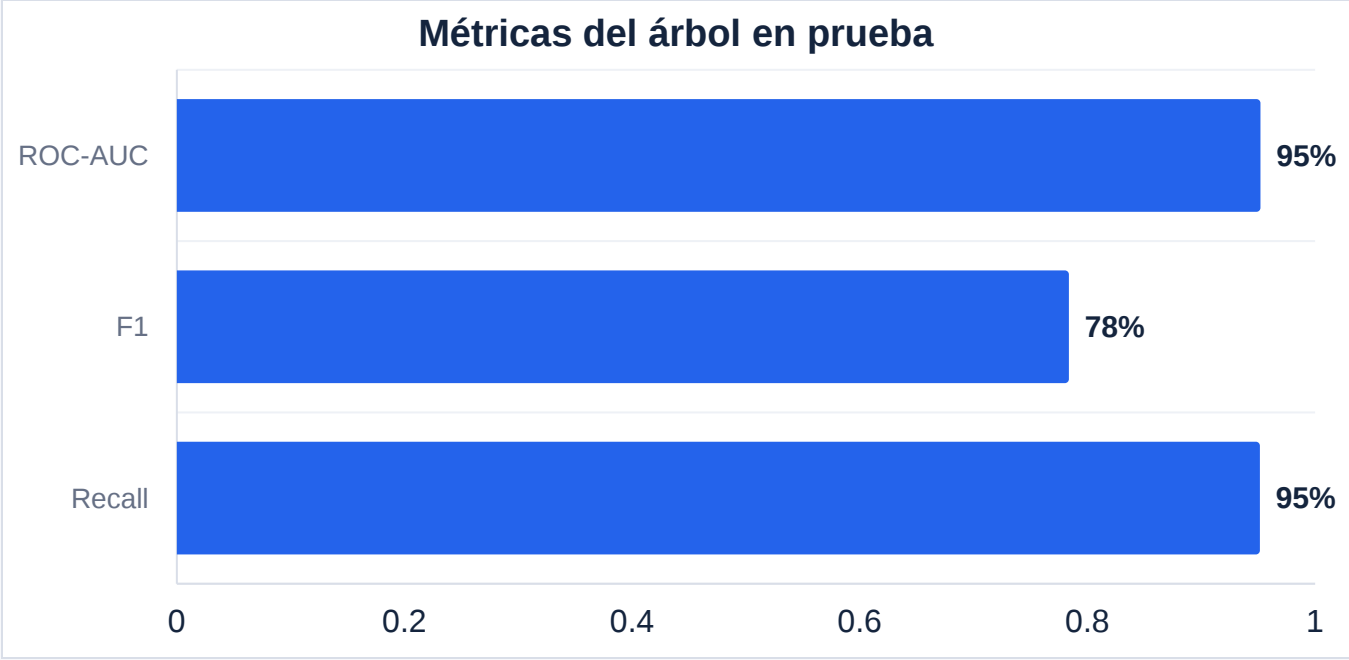
Minería F2: el P75 convierte la demora en una etiqueta histórica

El árbol se entrenó sobre variables disponibles antes del cierre y se evaluó en un conjunto de prueba.

4,329
minutos

demora_alta = 1
si la duración observada supera el P75

Sin cierre: demora_alta = NULL



Métricas de test. No representan un score de producción ni prueban causalidad.

Fuente: informe de Fase 2 y guía de defensa.

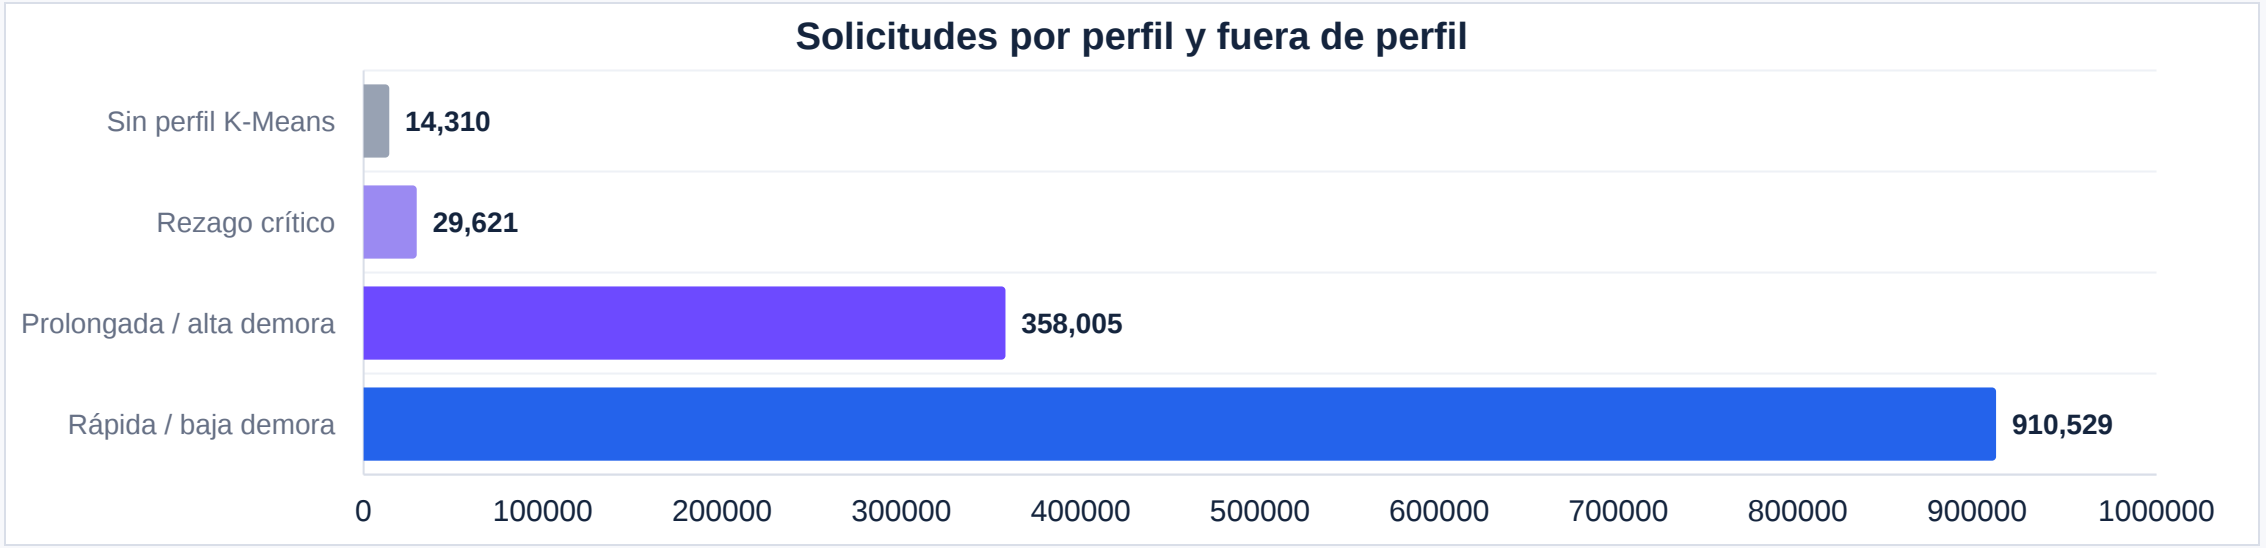
K-Means segmentó perfiles operativos, no tickets individuales

La terna agencia + tipo de reclamo + borough define el perfil. El universo no elegible queda visible.

912 perfiles iniciales F2 → **487** con volumen ≥ 100 → **480** modelados · K = 3

Silhouette = 0.421
separación útil, todavía moderada

BI actual: 481 perfiles



1,298,155 segmentadas + 14,310 sin perfil = 1,312,465 solicitudes

Fuente: validación del modelo BI. La cobertura actual es 98.91%; F2 original documentó 480 perfiles.

El árbol prioriza revisión, pero sus límites siguen visibles

La métrica clave es Recall en prueba. La clasificación histórica no equivale a predicción productiva.

95.15%

Recall en prueba

Predictores válidos

agency · complaint_type · borough
canal · mes · día de semana

Excluidos para evitar fuga: duración, estado, ID y coordenadas



Límites

Sin validación temporal · sin prueba causal · sin score por solicitud en producción

Fuente: informe de Fase 2. Recall, F1 y AUC son métricas del conjunto de prueba.

Panorama Power BI: una lectura del universo completo

La página 1 combina volumen, mediana observada, demora alta y solicitudes sin duración.

1,312,465
solicitudes distintas

330 min
mediana observada

La primera lectura debe responder tres preguntas: cuánto entra, cuánto tarda y qué parte no puede clasificarse por falta de duración.



Lectura de gestión

La demora alta se calcula solo sobre cierres observados; los 63,467 casos sin duración permanecen como sin clasificar.

Fuente: PBIX final y validación del modelo. Las cifras se presentan como conteos del universo, no como captura de pantalla.

Diagnóstico operativo: dónde concentrar capacidad

La página 2 cruza mediana observada, borough, canal y estado sin convertir NULL en demora normal.

330 min
mediana global observada

4,329 min
P75 histórico; no es SLA

63,467
sin duración observada

Ejemplo de drilldown interactivo

Borough / agencia / canal

Aplicar un filtro y leer el volumen y la mediana observada resultantes

Preguntas que responde el tablero

¿Qué borough, agencia o canal concentra volumen?
¿Dónde sube la mediana observada?
¿Qué casos requieren revisión por falta de duración?

Fuente: PBIX final y validación del modelo. El drilldown de Bronx es un ejemplo de lectura, no una conclusión causal.

Segmentación: cobertura alta, universo completo

Los tres perfiles sirven para orientar investigación y capacidad. El cuarto renglón solo identifica casos fuera de perfil.

481
perfiles modelados en BI

98.91%
cobertura de solicitudes



Cuadratura

1,298,155 segmentadas

+ 14,310 sin perfil

Fuente: modelo de perfiles K-Means y validación BI. `Sin perfil K-Means` preserva el 100% del universo.

Valor y costo: escenario, no ROI observado

Horizonte de 3 años. La sensibilidad cambia las horas de análisis evitadas, no las métricas de minería.

CAPEX

4,520 USD

OPEX anual

4,200 USD

TCO 3 años

17,120 USD

Supuesto de tarifa: 18 USD/hora

Escenario	Ahorro h/sem	Beneficio/año	ROI 3 años	Punto de equilibrio
Conservador	8	7,488 USD	31.2%	Mes 28
Base	16	14,976 USD	**162.4%**	Mes 14
Optimista	24	22,464 USD	293.6%	Mes 10

El informe modela ahorro de horas. No monetiza Recall, falsos negativos ni una adopción que todavía no existe.

Fuente: Documento Fase 3, sección de viabilidad. Marco de referencia: Horngren et al. (2012), Ross et al. (2019) y Storment & Fuller (2020).

Cierre y demo: de la evidencia a una acción concreta

La defensa termina mostrando una interacción real y nombrando lo que el modelo todavía no puede afirmar.

Tres decisiones defendibles

Conservar NULL y separar calidad de dato de demora alta.

Usar K-Means para orientar capacidad por perfil, no para etiquetar causalidad.

Usar el árbol como filtro de revisión humana, no como decisión automática.

Lo que sí sabemos

El tablero permite comparar volumen y demora con el mismo filtro.

Demo en 3 pasos

01 **Filtrar un borough**

Leer volumen y mediana observada con el filtro aplicado

02 **Aislar sin perfil**

14,310 solicitudes · la cuadratura se conserva

03 **Volver al universo**

1,312,465 solicitudes · P75 histórico 4,329 min

Fuentes: validación del modelo BI y guion de defensa. Marco ético: Ley de Protección de Datos Personales (2024).

Marco teórico y referencias académicas

Sustentación metodológica, normativa y bibliográfica de las Fases 1, 2 y 3 (documentos de referencia).

Data Warehouse y Modelado Dimensional

· Kimball, R., et al. (1998). The Data Warehouse Lifecycle Toolkit. Metodología de 10 etapas; hecho atómico dw.FactSolicitud y dimensiones conformadas.
· Microsoft Learn (2026). SQL Server Integration Services (SSIS). Flujos ETL y staging.
· NYC Open Data (2026). 311 Service Requests (erm2-nwe9). Fuente primaria de datos abiertos.

Finanzas, CAPEX/OPEX y FinOps

· Horngren, C. T., et al. (2012). Contabilidad de costos: un enfoque gerencial. Escenario de CAPEX (US$4,520) y OPEX anual (US$4,200).
· Ross, S. A., et al. (2019). Fundamentals of Corporate Finance. TCO 3 años (US$17,120), análisis de sensibilidad y ROI (31.2% a 293.6%).
· Storment, J. R., & Fuller, M. (2020). Cloud FinOps. Sostenibilidad y costos elásticos.

Minería de Datos y Proceso KDD

· Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. JMLR.
· Scikit-learn Developers (2026). Árboles CART con GridSearchCV y K-Means.
· Metodología KDD: selección, limpieza, transformación, minería y evaluación en prueba (Recall 95.15% en test; K=3 sobre 480 perfiles F2). La publicación BI actual reejecutada conserva 481 perfiles.

Operaciones y Marco Normativo Ético

· Richards, G. (2018). Warehouse Management. Gestión de cuellos de botella y balanceo de cuadrillas en perfiles de resolución prolongada.
· Asamblea Legislativa de El Salvador (2024). Ley para la Protección de Datos Personales (Decreto 144). Principios de minimización, anonimización espacial y supervisión humana obligatoria (Human-in-the-Loop) sin decisiones punitivas automáticas.